

TRƯỜNG ĐẠI HỌC KINH TẾ - ĐẠI HỌC ĐÀ NẴNG

KHOA THƯƠNG MẠI ĐIỆN TỬ

....📖....



**PHÂN TÍCH DỮ LIỆU GIAO DỊCH TRÊN NỀN TẢNG INSTACART NHẪM
TĂNG SỐ LƯỢNG SẢN PHẨM BÁN RA TRÊN MỖI ĐƠN HÀNG**

Giảng viên hướng dẫn: TS. Lê Diên Tuấn

Nhóm: 1

Thành viên: Đinh Hoài Nam

Bùi Quang Huy

Nguyễn Hoàng Duy

Đà Nẵng, 2026

MỤC LỤC

I.	TỔNG QUAN VỀ DỰ ÁN	3
1.	Giới thiệu vấn đề	3
1.1.	Bối cảnh	3
1.2.	Vấn đề	2
1.3.	Câu hỏi phân tích	2
2.	Mục tiêu dự án	2
3.	Tổng quan dữ liệu	2
3.1.	Tổng quan về dữ liệu	2
4.	Nhóm bảng giao dịch (Fact Tables)	3
4.1.	Logic-Join	3
5.	Kế hoạch phân tích dữ liệu	4
6.	Đầu ra dự án	8
II.	CƠ SỞ LÝ THUYẾT	8
1.	Quy trình chuẩn nghiệp vụ về khai phá dữ liệu (CRISP-DM)	8
2.	Nguyên lý Pareto và ứng dụng trong phân tích đóng góp ngành hàng	9
3.	Ma trận chéo sản phẩm trong phân tích giỏ hàng	9
4.	Phân khúc khách hàng RFM	9
5.	Lý thuyết về Luật kết hợp	10
5.1.	Item và Itemset	10
5.2.	Giao dịch (Transaction)	11
5.3.	Tập mục phổ biến (Frequent Itemset)	11
5.4.	Độ hỗ trợ (Support)	11
5.5.	Độ tin cậy (Confidence)	11
5.6.	Độ nâng (Lift)	12
6.	Kmean-Cluster và chọn số cụm thích hợp với Elbow và Silhouette	12

7.	Apriori và cách tối ưu trong dữ môi trường dữ liệu lớn	15
8.	Sử dụng luật kết hợp cho thuật toán đề xuất (Base_recommend)	18
III.	KẾT QUẢ DỰ ÁN	19
1.	Tiền xử lí dữ liệu	19
2.	Phân tích khám phá (EDA)	21
3.	Dashboard phân tích	25
3.1.	Tổng quan	25
3.2.	Sản phẩm	30
3.3.	Khách hàng	36
3.4.	Đề xuất	39
4.	Xây dựng mô hình	40
4.1.	Phân cụm Kmean	40
4.2.	Luật kết hợp cho từng cụm khách hàng	53
4.3.	Hệ thống đề xuất dựa trên luật kết hợp	61
IV.	KẾT LUẬN	63
V.	DANH MỤC TÀI LIỆU THAM KHẢO	66

I. TỔNG QUAN VỀ DỰ ÁN

1. Giới thiệu vấn đề

1.1. Bối cảnh

Instacart là nền tảng thương mại điện tử trong lĩnh vực grocery tại Mỹ, cho phép người dùng đặt hàng thực phẩm trực tuyến từ nhiều chuỗi siêu thị khác nhau.

Dữ liệu giao dịch của Instacart có các đặc điểm:

- Khối lượng đơn hàng, sản phẩm, khách hàng lớn
- Mỗi đơn hàng chứa nhiều sản phẩm (basket-based data)

- Có lịch sử mua lặp lại (reorder behavior)

1.2. Vấn đề

Trong mô hình kinh doanh của Instacart, mỗi đơn hàng không chỉ phản ánh nhu cầu mua sắm tức thời của khách hàng mà còn là cơ hội để gia tăng giá trị giao dịch thông qua việc mở rộng số lượng sản phẩm trong cùng một giỏ hàng. Do đó, một trong những bài toán trọng tâm là **tối đa hóa số sản phẩm trong mỗi lần khách hàng mua (basket size)**. Để đạt được điều đó cần phải nắm rõ hành vi của từng nhóm khách hàng và đề xuất sản phẩm phù hợp cho khách hàng đó

1.3. Câu hỏi phân tích

Làm thế nào để tối đa hóa số sản phẩm mỗi lần mua hàng của khách hàng mỗi lần mua hàng ?

2. Mục tiêu dự án

Mục tiêu của dự án là xây dựng một hệ thống đề xuất sản phẩm dựa trên dữ liệu giỏ hàng từ nền tảng Instacart nhằm khai thác hành vi mua sắm thực tế của khách hàng. Hệ thống tập trung vào việc xác định các sản phẩm có khả năng được mua kèm và chuyển hóa thành cơ chế gợi ý khi người dùng thêm sản phẩm vào giỏ hàng.

Thông qua đó, dự án hướng tới việc gia tăng số lượng sản phẩm trong mỗi đơn hàng bằng cách hỗ trợ các quyết định bán chéo dựa trên dữ liệu, đồng thời cung cấp một mô hình có thể áp dụng trong việc thiết kế gợi ý sản phẩm và tối ưu hóa giá trị mỗi giao dịch.

3. Tổng quan dữ liệu

3.1. Tổng quan về dữ liệu

Bộ dữ liệu gồm 5 bảng chính, được tổ chức theo mô hình quan hệ nhằm mô tả hành vi mua sắm của khách hàng ở cấp độ đơn hàng và sản phẩm. Các bảng liên kết với nhau thông qua khóa chính và khóa ngoại, cho phép truy vết xuyên suốt từ người dùng đến đơn hàng, sản phẩm và danh mục.

Với hơn 3.4 triệu đơn hàng và hơn 32 triệu dòng chi tiết sản phẩm, đây là một bộ dữ liệu có quy mô lớn, phù hợp cho các bài toán phân tích hành vi và khai thác dữ liệu nâng cao.

Nhóm bảng danh mục (Dimension Tables)

Hai bảng **aisles (134 kệ hàng)** và **departments (21 ngành hàng)**, đóng vai trò phân loại sản phẩm theo hai cấp độ: kệ hàng (aisle) và ngành hàng (department). Đây là các bảng danh mục giúp chuẩn hóa dữ liệu và hỗ trợ phân tích theo từng nhóm sản phẩm.

Bảng **products** đóng vai trò trung gian, chứa gần 50,000 sản phẩm và liên kết trực tiếp với cả aisles và departments. Nhờ đó, toàn bộ hệ thống dữ liệu có thể tổ chức theo cấu trúc phân cấp (hierarchy), phục vụ cho việc phân tích từ tổng quan đến chi tiết.

4. Nhóm bảng giao dịch (Fact Tables)

Bảng **orders** lưu thông tin tổng quan của từng đơn hàng, bao gồm mã người dùng, thứ tự đơn, thời điểm mua (giờ trong ngày và ngày trong tuần), cùng với khoảng cách giữa các lần mua (days_since_prior_order). Với hơn 3.4 triệu dòng, bảng này là nền tảng để phân tích hành vi theo thời gian và vòng đời khách hàng.

Bảng **order_products__prior** chứa chi tiết các sản phẩm trong từng đơn hàng lịch sử, với hơn 32 triệu dòng dữ liệu. Mỗi dòng đại diện cho một sản phẩm trong một đơn hàng, kèm theo thứ tự thêm vào giỏ (add_to_cart_order) và trạng thái mua lại (reordered). Đây là bảng fact quan trọng nhất, cho phép phân tích hành vi mua ở mức chi tiết như giỏ hàng, tần suất mua lại và mối quan hệ giữa các sản phẩm.

4.1. Logic-Join

Bảng trái	Key	Bảng phải	Key
orders	order_id	order_products__prior	order_id
order_products__prior	product_id	products	product_id

products	aisle_id	aisles	aisle_id
products	department_id	departments	department_id
orders	user_id	orders	user_id
products	department_id	departments	department_id
products	aisle_id	aisles	aisle_id

Bộ dữ liệu bao gồm 206,209 khách hàng duy nhất và hơn 3.4 triệu đơn hàng, cung cấp cái nhìn toàn diện về hành vi mua sắm. Một điểm cần lưu ý là trường `days_since_prior_order` có giá trị null ở đơn hàng đầu tiên của mỗi khách hàng (`order_number = 1`). Đây là đặc điểm logic của dữ liệu do chưa có giao dịch trước đó, không phải lỗi thiếu dữ liệu.


Ngoài ra, biến `reordered` phản ánh việc khách hàng có mua lại sản phẩm hay không, là yếu tố quan trọng để phân tích lòng trung thành và hành vi tiêu dùng lặp lại. Trường `add_to_cart_order` cung cấp thông tin về thứ tự thêm sản phẩm vào giỏ, giúp hiểu sâu hơn về hành vi mua trong từng phiên giao dịch.

5. Kế hoạch phân tích dữ liệu

#	Bước	Input	Xử lý chính	Output
1	Data Preparation	Orders, Products, Order_product_prior	- Xử lý missing - Xử lý trùng lặp	Bộ dữ liệu đã xử lý

2	Feature Engineering	Orders, Products, Order_product_prior	- Tạo 9 đặc trưng hành vi - Chuẩn hóa bằng MinMaxScaler - Loại outliers bằng IQR	customer_features.csv
3	EDA	Orders, Products, Order_product_prior customer_features.csv	Phân tích khám phá bộ dữ liệu	Báo cáo phân tích khám phá
3	Dashboard	Orders, Products, Order_product_prior	Trực quan hóa với Dashboard	Dashboard
4	Customer Segmentation	Dataset feature	- K-Means clustering - Chọn k bằng Elbow - Phân tích tìm ra đặt điểm mỗi cụm	Customer_segmentation.csv
5	Association Rules Mining	Orders, Products, Order_product_prior + cluster	- Chạy mô hình luật kết hợp theo từng cluster - Trực quan hóa kết quả đầu ra	AR_Cluster_0.csv AR_Cluster_1.csv AR_Cluster_2.csv

				Báo cáo phân tích về các cụm
6	Recomendation	AR_Cluster_0.csv AR_Cluster_1.csv AR_Cluster_2.csv	Xây dựng hệ thống đề xuất Demo web để trực quan kết quả	Web/app demo Recommendation system
7	Report	Toàn bộ thông tin dự án	Viết báo cáo về các kết quả đạt được tổng hợp insight + đề xuất	Final_report



6. Đầu ra dự án

Final_report.pdf

Danh sách file đính kèm:

- 1.1. customer_features.csv
- 1.2. Customer_segmentation.csv
- 1.3. Association_Rules_Cluster_0.csv
- 1.4. Association_Rules_Cluster_1.csv
- 1.5. Association_Rules_Cluster_2.csv
- 1.6. ar_boxplot_clusters_comparison.png
- 1.7. Ar_correlation_heatmap.png
- 1.8. Dashboard
- 1.9. Source code Web/app demo + luật kết hợp + phân cụm

II. CƠ SỞ LÝ THUYẾT

1. Quy trình chuẩn nghiệp vụ về khai phá dữ liệu (CRISP-DM)

Dự án được triển khai dựa trên khung tham chiếu CRISP-DM, một quy trình tiêu chuẩn hóa giúp kết nối giữa kỹ thuật dữ liệu và mục tiêu kinh doanh (Wirth & Hipp, 2000).

Quy trình này gồm 6 giai đoạn lặp lại, bắt đầu từ việc thấu hiểu nghiệp vụ bán lẻ của Instacart để xác định các bài toán về giỏ hàng và khách hàng. Sau đó, dữ liệu trải qua quá trình làm sạch và kỹ thuật đặc trưng để đảm bảo tính sẵn sàng cho việc xây dựng mô hình.

Việc áp dụng CRISP-DM giúp dự án duy trì tính logic, đảm bảo rằng mọi biểu đồ hay mô hình học máy được tạo ra đều trực tiếp phục vụ việc giải quyết các khó khăn trong vận hành và tiếp thị của doanh nghiệp.

2. Nguyên lý Pareto và ứng dụng trong phân tích đóng góp ngành hàng

Nguyên lý Pareto, hay quy luật 80/20, là cơ sở lý thuyết quan trọng để đánh giá mức độ tập trung của dữ liệu (Koch, 1998). Trong bối cảnh phân tích Instacart, nguyên lý này giả định rằng khoảng 80% tổng đơn hàng thường được đóng góp bởi 20% nhóm ngành hàng chủ lực.

Việc ứng dụng biểu đồ Pareto trên Dashboard cho phép doanh nghiệp phân loại các ngành hàng thành hai nhóm: nhóm "thiểu số quan trọng" và nhóm "đa số thứ yếu". Kết quả phân tích này là căn cứ khoa học để nhà quản lý ưu tiên nguồn lực tối ưu hóa chuỗi cung ứng cho các ngành hàng trọng yếu, thay vì dàn trải ngân sách cho toàn bộ danh mục sản phẩm.

3. Ma trận chéo sản phẩm trong phân tích giỏ hàng

Ma trận chéo sản phẩm là một công cụ trực quan hóa dựa trên lý thuyết về tần suất xuất hiện đồng thời của các thực thể trong một tập hợp, thường được ứng dụng trong khai phá luật kết hợp (Agrawal et al., 1993).

Cơ sở lý thuyết của ma trận này dựa trên việc thống kê số lần các cặp sản phẩm được đặt mua cùng nhau trong cùng một đơn hàng. Trục ngang và trục đứng của ma trận đại diện cho danh mục sản phẩm, trong khi các ô giao thoa thể hiện cường độ kết hợp thông qua mật độ màu sắc hoặc giá trị số.

Đây là nền tảng để nhận diện các sản phẩm "mồi" và sản phẩm "kèm theo", giúp doanh nghiệp xây dựng các chiến lược bán chéo dựa trên thói quen mua sắm thực tế.

4. Phân khúc khách hàng RFM

Mô hình RFM (Recency – Frequency – Monetary) là một phương pháp phân tích hành vi khách hàng phổ biến trong lĩnh vực marketing và phân tích dữ liệu, được sử dụng để đánh giá giá trị và mức độ tương tác của khách hàng dựa trên lịch sử giao dịch.

- **Recency (R)** đo lường khoảng thời gian kể từ lần mua gần nhất của khách hàng, phản ánh mức độ “mới” trong tương tác; khách hàng mua càng gần hiện tại thì khả năng quay lại càng cao.

- **Frequency (F)** thể hiện tần suất mua hàng, tức số lượng đơn hàng mà khách hàng đã thực hiện trong một khoảng thời gian nhất định; tần suất cao cho thấy mức độ gắn bó lớn.
- **Monetary (M)** đại diện cho giá trị chi tiêu của khách hàng, thường được tính bằng tổng hoặc trung bình giá trị đơn hàng.

Việc áp dụng RFM giúp doanh nghiệp chuyển đổi dữ liệu giao dịch thành thông tin có ý nghĩa, từ đó cá nhân hóa chiến lược tiếp thị, tối ưu hóa giữ chân khách hàng và gia tăng giá trị vòng đời (Customer Lifetime Value). Trong các hệ thống phân tích hiện đại, RFM thường được kết hợp với trực quan hóa (dashboard) và các kỹ thuật phân cụm để nâng cao khả năng diễn giải và ra quyết định.

5. Lý thuyết về Luật kết hợp

Luật kết hợp (Association Rules) là một kỹ thuật trong khai phá dữ liệu, được sử dụng để phát hiện các mối quan hệ đồng xuất hiện giữa các phần tử trong tập dữ liệu giao dịch. Một luật kết hợp có dạng:

$X \Rightarrow Y$

Trong đó:

- X và Y là các tập mục (itemset)
- $X \cap Y = \emptyset$
- X (Vế trái - Antecedent): tập hợp các mặt hàng đã mua
- Y (Vế phải - Conséquent): tập hợp các mặt hàng có khả năng mua thêm

Luật này biểu diễn mối quan hệ: khi tập mục X xuất hiện trong một giao dịch, thì tập mục Y có xu hướng xuất hiện cùng. Trước tiên hãy tìm hiểu các định nghĩa trong luật kết hợp.

5.1. Item và Itemset

Item là tập hợp tất cả các phần tử cơ bản xuất hiện trong dữ liệu phân tích. Mỗi phần tử trong tập này đại diện cho một đơn vị quan sát độc lập, ví dụ như một sản phẩm, một dịch vụ hoặc một hành vi cụ thể. (Kí hiệu I)

Itemset là một tập con của Item

5.2. Giao dịch (Transaction)

Giao dịch là một đơn vị dữ liệu quan sát, trong đó chứa một tập các mục xuất hiện đồng thời tại một thời điểm hoặc trong một ngữ cảnh cụ thể. (kí hiệu T)

Tập hợp tất cả giao dịch được gọi là cơ sở dữ liệu giao dịch (kí hiệu D)

5.3. Tập mục phổ biến (Frequent Itemset)

Một tập mục được gọi là phổ biến nếu nó xuất hiện trong tập dữ liệu với tần suất không nhỏ hơn một ngưỡng xác định trước.

5.4. Độ hỗ trợ (Support)

Độ hỗ trợ của một Itemset X là tỷ lệ số giao dịch trong tập dữ liệu chứa tập mục đó trên tổng số giao dịch. Độ hỗ trợ được định nghĩa là xác suất xuất hiện của luật đó trong cơ sở dữ liệu giao dịch. Phản ánh mức độ xuất hiện của itemset trong toàn bộ cơ sở dữ liệu

Công thức

$$Support(X) = \frac{|\{T_i \in D : X \subseteq T_i\}|}{|D|}$$

(Số giao dịch chứa itemset ở đây là X chia cho tổng số giao dịch)

5.5. Độ tin cậy (Confidence)

Độ tin cậy đo lường xác suất mà Y xuất hiện trong các giao dịch đã chứa X nghĩa là tỉ số mà số giao dịch có cả Y và X trong số giao dịch có X. Phản ánh xác suất xuất hiện của Y khi đã có X.

Công thức

$$Confidence(X \Rightarrow Y) = \frac{Support(X \cup Y)}{Support(X)}$$

5.6. Độ nâng (Lift)

Lift được sử dụng để so sánh xác suất đồng thời của hai tập mục với trường hợp chúng độc lập. Cũng có thể hiểu trong 1 luật $X \Rightarrow Y$ khi mua sản phẩm X thì xác suất mua của sản phẩm Y sẽ là Lift nhân với xác suất mua tự nhiên của chính Y

Công thức

$$Lift(X \Rightarrow Y) = \frac{Support(X \cup Y)}{Support(X) \cdot Support(Y)}$$

Kết luận

Luật kết hợp là phương pháp khai phá dữ liệu nhằm phát hiện mối quan hệ đồng xuất hiện giữa các tập mục trong cơ sở dữ liệu giao dịch. Dựa trên các khái niệm đã trình bày gồm item, itemset, giao dịch và tập mục phổ biến, quá trình xây dựng luật kết hợp được thực hiện thông qua ba thước đo chính: Support, Confidence và Lift. Trong đó, Support đảm bảo các mẫu được xem xét có tần suất xuất hiện đủ lớn trong dữ liệu; Confidence phản ánh xác suất suy diễn từ vế trái sang vế phải; còn Lift cho phép đánh giá mối quan hệ giữa hai tập mục so với trường hợp độc lập. Việc kết hợp ba thước đo này giúp lọc ra các luật không chỉ xuất hiện thường xuyên mà còn có ý nghĩa về mặt quan hệ, từ đó hỗ trợ các bài toán thực tế như phân tích giỏ hàng, gợi ý sản phẩm và tối ưu chiến lược kinh doanh.

6. Kmean-Cluster và chọn số cụm thích hợp với Elbow và Silhouette

K-Means là một thuật toán trong nhóm học không giám sát, được sử dụng để phân chia tập dữ liệu thành K cụm sao cho các điểm dữ liệu trong cùng một cụm có mức độ tương đồng cao hơn so với các cụm khác.

Các thuật ngữ cơ bản trong K-Means có thể tóm tắt ngắn gọn như sau:

- **Centroid (Tâm cụm):** Trung bình của các điểm trong một cụm, đại diện cho vị trí trung tâm của cụm đó.
- **K (Số cụm):** Số lượng cụm cần phân chia, được xác định trước khi chạy thuật toán.
- **Distance (Khoảng cách):** Thước đo độ gần giữa điểm dữ liệu và centroid (thường dùng Euclidean).
- **WCSS (Within-Cluster Sum of Squares):** Tổng bình phương khoảng cách từ các điểm đến centroid của cụm tương ứng, dùng để đánh giá mức độ phân cụm.

Nguyên lý hoạt động Kmean:

- Bước 1: Với số K cho trước khởi tạo tâm cụm(centroid) ngẫu nhiên
- Bước 2: Với mỗi điểm dữ liệu, tính khoảng cách (thông thường là khoảng cách Euclidean) đến từng tâm cụm sau đó gán điểm đó vào tâm cụm gần nhất
- Bước 3: Sau đó tính toán lại tâm cụm bằng cách tính trung bình khoảng cách của tất cả dữ liệu trong cụm
- Bước 4: Lặp lại 3 bước đầu đến khi không còn thay đổi các điểm dữ liệu giữa các cụm nữa hoặc thỏa mãn điều kiện dừng cho trước

Từ cơ chế này có thể thấy rằng K-Means là một phương pháp tối ưu lặp, trong đó mỗi vòng lặp sử dụng kết quả của vòng trước để cải thiện phân cụm. Kết quả cuối cùng là một cấu trúc cụm mà tại đó không thể tiếp tục giảm WCSS thông qua việc gán lại điểm hoặc cập nhật centroid, tương ứng với một nghiệm hội tụ phụ thuộc vào dữ kiện đầu vào và cách khởi tạo ban đầu.

Phương pháp Elbow cung cấp cách tiếp cận dựa trên dữ kiện WCSS để lựa chọn K bằng cách xác định điểm mà việc tăng số cụm không còn làm giảm đáng kể sai số. Việc kết hợp K-Means và Elbow cho phép xây dựng mô hình phân cụm với số cụm có cơ sở từ dữ liệu thay vì lựa chọn tùy ý.

Về nguyên lý, Elbow dựa trên việc theo dõi sự thay đổi của hàm mục tiêu WCSS (Within-Cluster Sum of Squares), tức là tổng bình phương khoảng cách từ các điểm dữ

liệu đến centroid của cụm mà chúng thuộc về [hoặc SSE (Sum of Squared Errors),...]. Khi số cụm K tăng, số lượng điểm trong mỗi cụm giảm, dẫn đến khoảng cách nội cụm giảm, do đó WCSS luôn giảm khi K tăng.

Quy trình thực hiện phương pháp Elbow gồm các bước sau:

- Chọn một khoảng giá trị cho K (ví dụ: từ 1 đến 10)
- Với mỗi giá trị K, chạy thuật toán K-Means và tính WCSS
- Vẽ đồ thị với:
 - Trục hoành: số cụm K
 - Trục tung: giá trị WCSS

Từ dữ kiện của đồ thị, ta quan sát xu hướng giảm của WCSS theo K. Ban đầu, khi K tăng từ nhỏ, WCSS giảm nhanh do việc phân cụm giúp giảm đáng kể khoảng cách nội cụm. Tuy nhiên, sau một điểm nhất định, tốc độ giảm của WCSS chậm lại rõ rệt.

Trong bài toán phân cụm, việc xác định số cụm k đóng vai trò quyết định đến cấu trúc kết quả. Một trong các phương pháp định lượng phổ biến là hệ số Silhouette, được sử dụng để đánh giá đồng thời mức độ liên kết trong cụm và mức độ tách biệt giữa các cụm. Phương pháp này không yêu cầu nhãn dữ liệu, phù hợp với bài toán học không giám sát.

Với mỗi điểm dữ liệu i , hệ số Silhouette được xác định dựa trên hai đại lượng: $a(i)$ là khoảng cách trung bình từ điểm i đến các điểm khác trong cùng cụm, và $b(i)$ là khoảng cách trung bình nhỏ nhất từ i đến các điểm thuộc cụm gần nhất khác. Giá trị Silhouette của điểm được tính như sau:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

Giá trị $s(i)$ nằm trong khoảng từ -1 đến 1. Khi $s(i)$ tiến gần 1, điều này cho thấy $a(i) < b(i)$, tức là điểm dữ liệu nằm gần các điểm trong cùng cụm hơn so với cụm khác.

Ngược lại, nếu $s(i) < 0$, khi đó $a(i) > b(i)$, cho thấy khả năng điểm dữ liệu bị gán sai cụm.

Silhouette score của toàn bộ mô hình được tính bằng trung bình cộng giá trị $s(i)$ của tất cả các điểm dữ liệu. Trong quá trình lựa chọn số cụm, người ta thực hiện phân cụm với nhiều giá trị k khác nhau và tính Silhouette score tương ứng. Giá trị k được chọn là giá trị làm cực đại Silhouette score trung bình, do tại đó dữ liệu đạt được trạng thái mà khoảng cách trong cụm là nhỏ hơn và khoảng cách giữa các cụm là lớn hơn so với các lựa chọn khác.

Do được xây dựng trực tiếp từ hai đại lượng $a(i)$ và $b(i)$, phương pháp Silhouette phản ánh rõ ràng nguyên lý của phân cụm: tối thiểu hóa khoảng cách nội cụm và tối đa hóa khoảng cách liên cụm. Tuy nhiên, do cần tính khoảng cách giữa nhiều cặp điểm dữ liệu, chi phí tính toán của phương pháp này tăng theo kích thước dữ liệu, và có thể bị ảnh hưởng khi các cụm không có dạng hình học rõ ràng hoặc có mật độ phân bố không đồng đều.

7. Apriori và cách tối ưu trong dữ môi trường dữ liệu lớn

Thuật toán Apriori là một trong những phương pháp khai phá luật kết hợp (association rule mining) nổi tiếng. Mục tiêu chính của thuật toán là tìm ra các tập mục (itemsets) thường xuyên xuất hiện cùng nhau trong cơ sở dữ liệu giao dịch. Những tập mục này sau đó được sử dụng để xây dựng các luật kết hợp có ý nghĩa thống kê, hỗ trợ ra quyết định trong kinh doanh, thương mại điện tử và nhiều lĩnh vực khác.

Cốt lõi của Apriori dựa trên nguyên tắc “Apriori property”:

- Nếu một itemset là **phổ biến** $\rightarrow$ mọi tập con của nó cũng phải phổ biến
- Ngược lại, nếu một tập con **không phổ biến** $\rightarrow$ mọi tập cha chứa nó đều không phổ biến

Nguyên lý hoạt động:

- Bước 1: Quét toàn bộ cơ sở dữ liệu để đếm số lần xuất hiện của từng item riêng lẻ. Sau đó, chỉ giữ lại các item có support lớn hơn hoặc bằng ngưỡng ***min_sup***. Kết quả của bước này là tập L_1 .

- Bước 2: Từ tập L_1 , thuật toán tạo ra các cặp item. Sau khi sinh các cặp này, hệ thống lại quét toàn bộ dữ liệu một lần nữa để tính support cho từng cặp và loại bỏ những cặp không đạt ngưỡng. Tập còn lại được gọi là L_2 .
- Bước 3: quá trình này tiếp tục lặp lại. Từ L_2 , thuật toán sinh ra các 3-itemset (L_3), rồi tiếp tục quét dữ liệu để tính support và lọc theo min_sup . Quy trình này tiếp tục cho đến khi không còn tạo được tập L_k nào thỏa điều kiện.

Hạn chế của Apriori:

- Thuật toán Apriori mỗi lần sinh ra tập L đều phải quét qua dữ liệu 1 lần điều này tốn tài nguyên và không tối ưu với dữ liệu lớn
- Bên cạnh đó, Apriori sinh ra tập ứng viên (candidate itemset) thông qua phép join giữa các tập L . Tuy nhiên, số lượng candidate có thể tăng nhanh theo tổ hợp và 1 lần nữa làm tốn tài nguyên
- Thuật toán chỉ loại bỏ các tập không thỏa mãn điều kiện sau khi đã sinh candidate, nghĩa là nhiều tập không cần thiết vẫn được tạo ra trước khi bị loại.

Logical Operation (AND) based Algorithm: Thuật toán được đề xuất trong tài liệu sử dụng cách tiếp cận khác so với Apriori bằng việc chuyển đổi dữ liệu giao dịch sang dạng bảng logic nhị phân. Trong biểu diễn này, mỗi giao dịch được mã hóa thành một vector gồm các giá trị 0 và 1, trong đó giá trị 1 thể hiện sự xuất hiện của item trong giao dịch, còn 0 thể hiện không xuất hiện. Việc biểu diễn này tạo tiền đề để áp dụng trực tiếp các phép toán logic thay vì phải xử lý trên dữ liệu dạng tập hợp như trong Apriori.

Bảng dưới đây minh họa cấu trúc của logical table:

TID	I1	I2	I3	I4	I5
T1	1	1	1	1	1
T2	1	1	0	0	0

T3	0	0	0	1	1
----	---	---	---	---	---

Từ biểu diễn này, thuật toán tiến hành sinh frequent itemset bằng cách thực hiện phép toán AND giữa các vector giao dịch. Khi chọn hai giao dịch bất kỳ, phép AND sẽ xác định các item xuất hiện đồng thời trong cả hai giao dịch. Số lượng bit “1” trong kết quả của phép AND chính là số lần xuất hiện của itemset tương ứng, từ đó dùng để tính support .

Ví dụ, với hai giao dịch:

Vector	Giá trị
T1	1 1 1 1 1
T2	1 1 0 0 0
AND	1 1 0 0 0

Trong trường hợp này, kết quả có 2 bit “1”, nghĩa là itemset xuất hiện trong 2 giao dịch. Nếu giá trị này lớn hơn hoặc bằng ngưỡng support tối thiểu (min_sup), itemset sẽ được giữ lại, ngược lại sẽ bị loại bỏ.

Quy trình của thuật toán có thể được mô tả qua bảng sau:

Bước	Thao tác	Kết quả
1	Chọn 2 dòng trong logical table	2 giao dịch

2	Thực hiện AND	Vector giao
3	Đếm số bit “1”	Support
4	So sánh với min_sup	Giữ / loại

Quá trình này được lặp lại cho nhiều cặp giao dịch để xây dựng tập frequent itemset. Theo mô tả trong tài liệu, toàn bộ dữ liệu chỉ cần được quét một lần để xây dựng bảng logic ban đầu, sau đó mọi phép tính đều thực hiện trên bảng này .

Sau khi xác định được các frequent itemset, thuật toán tiếp tục sinh luật kết hợp bằng cách xét các tập con của itemset và tính toán độ đo confidence. Ví dụ trong tài liệu cho thấy các luật như “Bread → Milk” có confidence 100%, nghĩa là tất cả các giao dịch chứa Bread đều chứa Milk

8. Sử dụng luật kết hợp cho thuật toán đề xuất (Base_recommend)

Hệ thống đề xuất trong tài liệu được xây dựng dựa trên kỹ thuật **Association Rules**, với mục tiêu gợi ý sản phẩm phù hợp dựa trên các mối quan hệ đồng mua trong dữ liệu lịch sử. Dữ liệu đầu vào của hệ thống là tập các luật kết hợp đã được khai phá trước, mỗi luật có dạng:

$X \Rightarrow Y$

Trong đó, X là tập sản phẩm đã có trong giỏ hàng và Y là sản phẩm có khả năng được mua tiếp. Hệ thống không khai phá luật theo thời gian thực mà sử dụng các luật đã được tính toán sẵn từ dữ liệu , sau đó áp dụng để suy luận đề xuất cho người dùng .

Nguyên lý thuật toán:

Khi giỏ hàng trống, hệ thống sử dụng **support** để hiển thị các sản phẩm phổ biến nhất. Khi xuất hiện hành động thêm vào giỏ hàng thì thực hiện gợi ý theo chỉ số Score(Y) được tính theo công thức:

$$\text{Score}(X \Rightarrow Y) = \text{Confidence}(X \Rightarrow Y) * (\text{Lift}(X \Rightarrow Y) - 1)$$

Khi bỏ itemset vào giỏ hàng thì sẽ đề xuất theo **top (Score(Xi=>Y))**

Cuối cùng tạo thành danh sách đề xuất theo điểm Score(Y). Trong một số trường hợp, số lượng sản phẩm đề xuất từ các luật trực tiếp không đủ hệ thống sử dụng cơ chế fallback.

Fallback:

- Duyệt toàn bộ tập luật
- Lấy các sản phẩm chưa xuất hiện trong danh sách đề xuất
- Bổ sung theo thứ tự **Score** giảm dần

III. KẾT QUẢ DỰ ÁN

1. Tiền xử lí dữ liệu

Làm sạch và Tích hợp dữ liệu (Data Cleaning & Integration)

- Các thao tác thực hiện: Kết hợp (merge) dữ liệu từ 4 bảng gốc (products, orders, order_products__prior, departments) thông qua các khóa ngoại (product_id, department_id, order_id). Đặc biệt, tập dữ liệu được lọc để chỉ giữ lại các sản phẩm thuộc 7 nhóm hàng (departments) phổ biến nhất (bao gồm: produce, dairy eggs, snacks, beverages, frozen, pantry, bakery).
- Mục đích: Bảy nhóm hàng này chiếm khoảng 80% tổng số đơn hàng của Instacart. Việc lọc này giúp loại bỏ thông tin nhiễu từ các nhóm hàng vặt, giảm thiểu sự chồng chéo của bộ dữ liệu để tối ưu hóa tài nguyên tính toán, đồng thời tập trung quá trình khai phá vào các mẫu thói quen mua sắm mang tính đại diện cao nhất của khách hàng.

Trích xuất đặc trưng hành vi

- Các thao tác thực hiện: Từ dữ liệu giao dịch ở cấp độ đơn hàng (mỗi dòng là một sản phẩm trong giỏ hàng), dữ liệu được tổng hợp (groupby) theo định danh người dùng (user_id). Quá trình này tạo ra 9 đặc trưng mới mang ý nghĩa hành vi, bao gồm:

- Tần suất mua sắm: `total_orders` (tổng số đơn), `average_days_between_orders` (chu kỳ mua sắm).
- Quy mô và mức độ đa dạng: `avg_basket_size` (kích thước giỏ hàng), `unique_products` (số loại sản phẩm), `product_diversity`, `reorder_rate` (tỉ lệ mua lại đồ cũ).
- Thói quen sinh hoạt: `weekend_ratio` (tỉ lệ mua sắm vào cuối tuần), `night_order_ratio` (tỉ lệ mua ban đêm) và tạo biến `is_organic` sinh ra `organic_ratio_order` (tỉ lệ mua hàng hữu cơ).
- Mục đích: Chuyển đổi dữ liệu từ dạng bảng ghi nhận lịch sử (transactional data) sang dạng hồ sơ khách hàng (customer profile). Định dạng này là yêu cầu bắt buộc để có thể đưa vào các mô hình học máy theo dõi và phân nhóm (clustering) khách hàng.

Chuẩn hóa dữ liệu

- Các thao tác thực hiện: Áp dụng phương pháp Min-Max Scaling (MinMaxScaler) trên bảng đặc trưng 9 cột để nén hoặc kéo giãn dữ liệu về cùng một miền giá trị cố định là $[0, 1]$.
- Mục đích: Xử lý sự chênh lệch lớn về thang đo giữa các đặc trưng (ví dụ: `total_orders` mang giá trị số nguyên lớn, trong khi các tỷ lệ như `reorder_rate` chỉ dao động từ 0 đến 1). Việc chuẩn hóa đảm bảo thuật toán phân cụm K-Means (hoạt động dựa trên khoảng cách Euclidean) không bị chệch, giúp mọi đặc trưng đóng góp trọng số công bằng vào việc phân chia cụm.

Chuyển đổi dữ liệu cho Luật Kết Hợp

- Các thao tác thực hiện: Sau khi khách hàng được dán nhãn cụm (cluster), dữ liệu giao dịch nguyên thủy được cắt lát (slice) theo từng phân khúc. Tại đây, dữ liệu giao dịch định dạng danh sách (long format) biến đổi thành phân bố ma trận nhị phân (one-hot / basket matrix), trong đó mỗi hàng là một hóa đơn, mỗi cột là biểu diễn sự có mặt (True/1) hoặc vắng mặt (False/0) của một sản phẩm.

- Mục đích: Cung cấp đầu vào hợp lệ và phù hợp với cách thức tính toán cấu trúc mạng FP-tree của thuật toán khai phá luật kết hợp (FP-Growth/Apriori). Từ đó trích xuất ra các luật sản phẩm thường được mua kèm theo đúng đặc trưng của từng nhóm khách hàng đã phân cụm.



Toàn bộ quy trình tiền xử lý trên được cấu trúc thành các module xử lý riêng biệt trong mã nguồn:

- Giai đoạn 1 & 2 (Tích hợp & Trích xuất đặc trưng):
 - Tập xử lý: `data_feature_extraction.ipynb`
 - Kết quả (Output): Tạo ra file số liệu `customer_features.csv` (chứa hồ sơ hành vi của 206,209 khách hàng để sử dụng cho phân cụm).
- Giai đoạn 3 (Chuẩn hóa cho phân cụm):
 - Tập xử lý: `output.ipynb`
 - Kết quả (Output): Tạo ra file số liệu `customer_segmentation.csv` (chứa dữ liệu khách hàng đính kèm nhãn phân cụm 0, 1 hoặc 2).

2. Phân tích khám phá (EDA)

Phân tích hành vi đặt hàng (Bảng Orders)


Chúng ta sẽ bắt đầu bằng việc phân tích thời gian khách hàng mua sắm để tìm ra thời điểm "vàng" (Peak Hours & Peak Days)



Có thể thấy rằng, khách hàng có hành vi mua tập trung chủ yếu vào chủ nhật và thứ Hai, khung giờ mua cao điểm là từ 10-16 giờ hàng ngày.


Tần suất mua lại (Days_Since_Prior_Order)

Mất bao lâu để một khách hàng đã quen thuộc của Instacart quay trở lại mua thêm đơn mới? (Lưu ý: Null ở đây nghĩa là họ vừa mới mua đơn đầu tiên!).



Chu kỳ mua sắm của khách hàng tập trung chủ yếu từ 2-7 ngày và giảm dần tới các chu kỳ dài hơn. Tuy nhiên, có một bộ phận lớn khách hàng mua lặp lại với chu kỳ 30 ngày.


Top Sản Phẩm Bán Chạy



Biểu đồ cho thấy một sự thống trị tuyệt đối của nhóm hàng **thực phẩm tươi sống (Fresh Produce)**. Không có bất kỳ sản phẩm đóng gói, đồ gia dụng hay thực phẩm chế biến sẵn nào lọt vào top 20.

1. **Sản phẩm dẫn đầu:** Chuối (Banana) và Chuối hữu cơ (Bag of Organic Bananas) đứng đầu bảng với cách biệt rất lớn so với các vị trí còn lại.
2. **Xu hướng tiêu dùng:** Người dùng Instacart có xu hướng ưu tiên các sản phẩm **Organic (Hữu cơ)**. Có tới **15/20** sản phẩm trong danh sách là đồ hữu cơ.

Top Ngành Hàng (Departments & Aisles) Đem Lại Hiệu Suất Tốt Nhất



Phòng ban **Produce** có doanh số vượt xa các nhóm còn lại với hơn **9 triệu items**, gần gấp đôi nhóm đứng thứ hai là **Dairy Eggs** (Trứng & Sữa). Điều này chứng minh Instacart là nền tảng chủ lực cho việc "đi chợ hàng ngày" thay vì chỉ mua sắm đồ khô.

Bốn phòng ban dẫn đầu bao gồm *Produce*, *Dairy Eggs*, *Snacks*, và *Beverages* tạo thành một khoảng cách rất lớn so với phần còn lại. Đây là nhóm hàng tiêu dùng nhanh (FMCG) có tần suất mua lặp lại cực cao.


Các nhóm như *Bulk*, *Other*, *Missing*, *Pets*, *Alcohol* chiếm tỷ trọng rất nhỏ.

3. Dashboard phân tích

3.1. Tổng quan

Dashboard Overview cung cấp một cái nhìn tổng thể về hành vi mua sắm của khách hàng thông qua các chỉ số KPI cốt lõi, giúp đánh giá quy mô hoạt động, mức độ tương tác và xu hướng tiêu dùng.

Bên cạnh đó, dashboard được tích hợp **bộ lọc theo department (ngành hàng)**, cho phép người dùng linh hoạt thu hẹp phạm vi phân tích theo từng nhóm sản phẩm cụ thể, giúp so sánh sự khác biệt về hành vi mua sắm giữa các ngành hàng, từ đó hỗ trợ đánh giá hiệu suất, xác định nhóm ngành chủ lực và đưa ra các quyết định kinh doanh chính xác hơn.



3.1.1. KPI Card:

Total user	Total orders	Total Unit Sold	Median Basket Size	Median Orders per User	Median order gap	Reorder rate (User)
206,209	3,214,874	32,434,489	8	9	7	43.2%
100% of total	100%	100%	Avg. Basket Size: 10	Avg. No of orders: 16	Avg. Order gap: 11	of total

Trước hết, các KPI về quy mô như **Total Users** (tổng số khách hàng: 206,209), **Total Orders** (tổng số đơn hàng: 3,214,874) và **Total Unit Sold** (tổng số sản phẩm bán ra: 32,434,489) cho thấy nền tảng có lượng người dùng lớn và mức độ giao dịch cao. Điều

này phản ánh một hệ sinh thái mua sắm đã đạt độ ổn định, nơi hành vi tiêu dùng đủ rõ ràng để khai thác các mô hình phân tích nâng cao.


Xét theo hành vi mua trong mỗi đơn, **Median Basket Size** (số sản phẩm trung vị trong mỗi đơn: 8) cho thấy phần lớn khách hàng mua với quy mô giỏ hàng vừa phải. Trong khi đó, **Median Orders per User** (số đơn trung vị mỗi khách: 9) phản ánh đa số người dùng có tần suất mua ở mức trung bình.

Về tần suất mua, **Median Order Gap** (khoảng cách trung vị giữa hai đơn: 7 ngày) cho thấy khách hàng có xu hướng quay lại mua trong thời gian ngắn, hình thành chu kỳ tiêu dùng lặp lại. Điều này thể hiện hành vi mua mang tính thói quen, có thể dự đoán và tối ưu thông qua các chiến lược như nhắc mua lại hoặc cá nhân hóa thời điểm tiếp cận.

Cuối cùng, **Reorder Rate** (tỷ lệ mua lại trung bình trên mỗi khách hàng: 43.2%) phản ánh mức độ lặp lại trong hành vi tiêu dùng. Chỉ số này được tính bằng cách lấy trung bình tỷ lệ sản phẩm được mua lại của từng người dùng, cho thấy mức độ khách hàng quay lại với các sản phẩm đã mua trước đó. Giá trị tương đối cao cho thấy hành vi mua mang tính thói quen rõ rệt, đồng thời tạo nền tảng cho các bài toán như dự đoán mua lại và xây dựng hệ thống gợi ý sản phẩm.


Tổng thể, các KPI cho thấy hệ sinh thái mua sắm có tính lặp lại cao, khách hàng hình thành thói quen tiêu dùng rõ ràng và tồn tại sự phân hóa giữa các nhóm giá trị. Đây là cơ sở quan trọng để triển khai các phân tích sâu hơn như RFM segmentation, cohort analysis và tối ưu chiến lược marketing.

3.1.2. Sản phẩm Organic



Tiếp theo, **tỷ trọng Organic trong giỏ hàng (32%)** bổ sung góc nhìn về cấu trúc tiêu dùng. Dù chưa chiếm đa số, nhưng mức tỷ trọng này cho thấy khách hàng đã có xu hướng dịch chuyển sang các sản phẩm liên quan đến sức khỏe và chất lượng. Khi đặt trong bối cảnh các KPI trước đó (tần suất mua cao, hành vi lặp lại rõ rệt), insight quan trọng là nhóm sản phẩm Organic có tiềm năng trở thành một phần trong thói quen tiêu dùng, nếu được thúc đẩy đúng cách.

3.1.3. Thời gian mua sắm của khách hàng




Tiếp theo, biểu đồ thời gian mua sắm (phân bố theo giờ và ngày trong tuần) cho thấy hành vi mua tập trung vào **khung giờ trưa đến chiều (khoảng 10h–16h)**, với mức cao

nhất vào giữa ngày. Đồng thời, lưu lượng mua sắm tăng rõ vào **đầu tuần (Thứ 2)** và **cuối tuần (Chủ nhật)**.

Hành vi mua mang tính **theo lịch sinh hoạt**, khi khách hàng có xu hướng đặt hàng vào thời điểm rảnh hoặc chuẩn bị cho nhu cầu tiêu dùng trong tuần. Điều này cho phép tối ưu thời điểm triển khai khuyến mãi, push notification hoặc quảng cáo để đạt hiệu quả cao hơn.

3.1.4. Phân phối về hành vi mua


Đi sâu hơn từ các KPI tổng quan, các biểu đồ phân phối giúp làm rõ cấu trúc hành vi mua sắm và mức độ tương tác thực tế của khách hàng trên nền tảng. Thay vì chỉ nhìn vào giá trị trung bình, các phân phối này cho thấy cách hành vi được hình thành và phân hóa giữa các nhóm người dùng.




Biểu đồ **Số lượng sản phẩm mỗi đơn hàng (Basket Size Distribution)** cho thấy phần lớn đơn hàng tập trung ở mức thấp, với 63% đơn có ≤ 10 sản phẩm.

Phản ánh hành vi mua mang tính tiện lợi và thường phục vụ nhu cầu ngắn hạn, thay vì tích trữ. Tuy nhiên, vẫn tồn tại một nhóm nhỏ đơn hàng có quy mô lớn hơn, góp phần

kéo giá trị trung bình lên cao, cho thấy sự khác biệt giữa các nhóm khách hàng về nhu cầu và cách tiêu dùng.



Đối với **Số lượng đơn hàng theo mỗi khách hàng (Orders per User)**, có 56.64% khách hàng đặt ≤ 9 đơn, cho thấy phần lớn người dùng có mức độ tương tác ở mức trung bình. Tuy nhiên, phân phối lệch cho thấy tồn tại một nhóm khách hàng có tần suất mua rất cao, đóng vai trò là nhóm khách hàng giá trị.



Cuối cùng, **Khoảng cách giữa các lần đặt hàng (Order Gap)** tập trung mạnh quanh 7 ngày, cho thấy hành vi mua có tính chu kỳ rõ rệt theo tuần. Điều này phản ánh khách hàng đã hình thành thói quen tiêu dùng ổn định, đặc biệt trong các ngành hàng tiêu dùng nhanh. Điều này đặc biệt quan trọng vì cho phép doanh nghiệp dự đoán thời điểm mua tiếp theo và tối ưu các hoạt động như nhắc mua, khuyến mãi hoặc phân bổ tồn kho.

Tóm lại:



Thông qua Dashboard Overview cho thấy nền tảng có quy mô lớn với mức độ hoạt động cao và hành vi mua sắm mang tính lặp lại rõ rệt. Khách hàng có xu hướng mua với tần suất ổn định, hình thành chu kỳ tiêu dùng ngắn, đồng thời tồn tại sự phân hóa giữa nhóm khách hàng thông thường và nhóm giá trị cao.

Bên cạnh đó, các chỉ số như reorder rate và tỷ trọng Organic cho thấy hành vi tiêu dùng đang dần hình thành thói quen và có xu hướng dịch chuyển theo nhu cầu chất lượng.

3.2. Sản phẩm

Tiếp nối từ góc nhìn tổng quan về hành vi khách hàng, phần tiếp theo đi sâu vào cấu trúc danh mục sản phẩm nhằm xác định những ngành hàng đóng vai trò chính trong việc tạo ra đơn hàng.

3.2.1. Phân tích đóng góp của các ngành hàng




Sử dụng biểu đồ Pareto để thể hiện mức độ đóng góp của từng ngành hàng vào tổng số đơn hàng. Kết quả phân tích cho thấy một số ngành hàng chiếm tỷ trọng lớn nhất trong tổng số đơn hàng, bao gồm:

- Produce (rau củ và trái cây)
- Dairy Eggs (sữa và trứng)
- Snacks (đồ ăn nhẹ)
- Beverages (đồ uống)

Trong đó, Produce (rau củ và trái cây) chiếm tỷ trọng cao nhất với khoảng 29% tổng đơn hàng, tiếp theo là Dairy Eggs (sữa và trứng), nâng tỷ lệ tích lũy lên khoảng 46%. Điều này cho thấy các nhóm thực phẩm tươi sống và thiết yếu đóng vai trò trung tâm trong giỏ hàng của khách hàng.


Khi bổ sung các ngành hàng như Snacks, Beverages, Frozen, Pantry và Bakery, tỷ lệ tích lũy đạt gần 80% tổng số đơn hàng. Điều này cho thấy phần lớn giao dịch tập trung vào một số ngành hàng thực phẩm chính, phản ánh hành vi mua sắm chủ yếu xoay quanh các sản phẩm tiêu dùng hàng ngày.



Ngoài ra, các sản phẩm trong những ngành hàng này thường có tỷ lệ mua lại (reorder rate) cao (ví dụ với ngành hàng produce - rau củ) do phần lớn là các sản phẩm thực phẩm thiết yếu và được tiêu dùng thường xuyên. Vì vậy, chúng không chỉ đóng góp lớn vào số lượng đơn hàng mà còn đóng vai trò quan trọng trong việc duy trì tần suất mua sắm và tăng mức độ gắn bó của khách hàng với nền tảng.

3.2.2. Phân tích các sản phẩm bán chạy nhất

Biểu đồ "Top sản phẩm được mua nhiều nhất" cho thấy những sản phẩm có số lượng đơn hàng cao nhất trong hệ thống.



Trong đó, Banana là sản phẩm phổ biến nhất với hơn 472 nghìn đơn hàng, tiếp theo là Bag of Organic Bananas, Organic Strawberries và Organic Baby Spinach. Phần lớn các sản phẩm trong nhóm top đều thuộc nhóm trái cây và rau củ tươi.

Một điểm đáng chú ý là nhiều sản phẩm bán chạy thuộc nhóm thực phẩm hữu cơ (organic). Điều này cho thấy khách hàng trên Instacart có xu hướng ưu tiên các sản phẩm tươi sống và thực phẩm lành mạnh, đồng thời phản ánh nhu cầu ngày càng tăng đối với các sản phẩm liên quan đến sức khỏe và dinh dưỡng.

3.2.3. Phân tích các sản phẩm thường được thêm đầu tiên vào giỏ hàng

Treemap trong dashboard cho thấy những sản phẩm thường được thêm đầu tiên vào giỏ hàng của khách hàng.

Những sản phẩm thường được thêm vào giỏ hàng đầu tiên



Trong đó nổi bật gồm Banana, Bag of Organic Bananas, Organic Whole Milk, Organic Avocado và Limes. Đây chủ yếu là các thực phẩm thiết yếu có tần suất mua lặp lại cao, thường xuất hiện ở giai đoạn đầu của quá trình xây dựng giỏ hàng.

Những sản phẩm này có thể được xem như “hook products” hoặc “anchor products”, tức là các mặt hàng đóng vai trò kích hoạt quá trình mua sắm. Do đó, việc đảm bảo nguồn cung ổn định cho các sản phẩm này là rất quan trọng, bởi nếu chúng hết hàng, khách hàng có thể hủy bỏ hoặc không hoàn tất đơn hàng.

3.2.4. Phân tích các sản phẩm thường được mua cùng nhau

Tiếp theo, để hiểu sâu hơn về hành vi mua trong từng giỏ hàng, phân tích Market Basket Analysis được áp dụng nhằm xác định các cặp sản phẩm thường được mua cùng nhau.

Những sản phẩm thường được mua kèm

	Bag of Organic Bananas	Banana	Large Lemon	Limes	Organic Baby Spinach
Organic Hass Avocado	62,341	31,222	15,005	20,030	34,901
Organic Strawberries	61,628	56,156	16,305	18,999	38,134
Organic Yellow Onion	24,574	16,695	11,045	12,756	19,707
Organic Zucchini	22,632	19,318	11,303	10,182	20,415
Strawberries	17,611	41,232	11,393	7,994	13,751

Kết quả cho thấy một số sản phẩm đóng vai trò “trung tâm” với tần suất xuất hiện cùng các sản phẩm khác rất cao, điển hình là Banana và Bag of Organic Bananas. Các sản phẩm này thường xuyên được mua kèm với nhiều loại trái cây và rau củ khác như Organic Strawberries, Organic Baby Spinach hay Organic Hass Avocado, cho thấy chúng là những sản phẩm nền tảng trong giỏ hàng.

Hành vi mua không diễn ra độc lập theo từng sản phẩm, mà theo cụm tiêu dùng (consumption bundle), đặc biệt tập trung vào nhóm thực phẩm tươi sống và Organic. Điều này phản ánh xu hướng mua sắm theo nhu cầu sử dụng thực tế (ví dụ: chuẩn bị bữa ăn, ăn healthy), thay vì mua rời rạc từng sản phẩm

.

Tóm lại:


Phân tích ở cấp độ sản phẩm cho thấy nhu cầu tiêu dùng tập trung mạnh vào nhóm thực phẩm tươi sống, đặc biệt là trái cây và sản phẩm Organic. Một số sản phẩm như Banana và Bag of Organic Bananas đóng vai trò “sản phẩm lõi”, xuất hiện với tần suất cao và thường xuyên nằm trong giỏ hàng.

Bên cạnh đó, hành vi mua sắm có xu hướng diễn ra theo cụm sản phẩm thay vì riêng lẻ, với các nhóm như trái cây – rau củ – sản phẩm Organic thường được mua cùng nhau. Điều này cho thấy khách hàng mua theo nhu cầu sử dụng thực tế (ăn uống, healthy lifestyle) và hình thành các pattern tiêu dùng rõ ràng.

Tổng thể, danh mục sản phẩm mang tính tập trung cao, với một số sản phẩm và ngành hàng đóng vai trò dẫn dắt, tạo cơ hội lớn cho các chiến lược như tối ưu danh mục chủ lực, cross-sell và xây dựng hệ thống gợi ý sản phẩm.

3.3. Khách hàng

Sau khi phân tích hành vi ở cấp độ sản phẩm và ngành hàng, bước tiếp theo là đi sâu vào khách hàng, nhằm hiểu rõ sự khác biệt trong mức độ tương tác và giá trị giữa các nhóm người dùng.



Phân khúc khách hàng được xây dựng dựa trên ba KPI cốt lõi từ phần Overview gồm **Frequency** (Order per User - số đơn hàng), **Recency** (Order Gap - khoảng cách giữa các lần mua) và **Monetary** (Reorder Rate - tỷ lệ mua lại (không có dữ liệu về Thành Tiền)). Ba chỉ số này phản ánh lần lượt mức độ tương tác, tính gần đây của hành vi mua và mức độ trung thành của khách hàng, từ đó mô tả đầy đủ hành vi tiêu dùng.

Khác với cách tiếp cận RFM truyền thống (thường chia theo quantile như top 20%, top 40%...), mô hình này sử dụng ngưỡng giá trị tuyệt đối (rule-based threshold). Các ngưỡng được xác định dựa trên phân phối thực tế của dữ liệu (median, average và pattern hành vi trong Overview), nhằm đảm bảo mỗi phân khúc phản ánh một trạng thái hành vi rõ ràng và có ý nghĩa kinh doanh, thay vì chỉ mang tính tương đối giữa các nhóm. Chi tiết như sau:

- **Loyal:** Frequency ≥ 20 (cao hơn đáng kể so với Mean Order per User = 16), Recency ≤ 8 ngày (gần Median Order Gap = 7), Reorder Rate $\geq 60\%$ (cao hơn nhiều so với mức chung 43.2%)
- **Regular:** Frequency ≥ 10 (xấp xỉ Median Order per User = 9), Recency ≤ 12 ngày (gần Mean Order Gap = 11), Reorder Rate $\geq 40\%$ (xấp xỉ mức trung bình)
- **Occasional:** Frequency ≥ 5 (dưới Median), Recency > 12 ngày (cao hơn mean), Reorder Rate $\geq 20\%$ (thấp hơn mức chung)
- **New Customers:** Frequency < 5 (rất thấp so với median), Recency ≤ 12 ngày
- **Churn Risk:** Frequency thấp (< 5), Recency cao (> 12 ngày), Reorder Rate thấp ($< 20\%$)


Từ đó đảm bảo mỗi phân khúc phản ánh mức độ “cao hơn – ngang – thấp hơn” so với hành vi trung bình của toàn bộ khách hàng.

Phân khúc khách hàng



Qua đó ta thấy phân khúc cho thấy cấu trúc khách hàng đang nghiêng về các nhóm có mức độ gắn bó thấp, với Occasional chiếm 41.8% và Churn Risk chiếm 30.6%. Điều này phản ánh phần lớn khách hàng chưa duy trì được thói quen mua ổn định, với tần suất và mức độ quay lại thấp hơn so với mức trung bình của hệ thống.

Trong khi đó, Regular (15.9%) đóng vai trò là nhóm trung gian, có hành vi gần với mức chuẩn và là đối tượng tiềm năng để nâng cấp lên nhóm giá trị cao hơn. Ngược lại, Loyal chỉ chiếm 8.1%, tuy quy mô nhỏ nhưng lại là nhóm đóng góp lớn nhất về giá trị nhờ tần suất mua cao, chu kỳ ngắn và tỷ lệ mua lại vượt trội.



Phân tích hành vi theo từng phân khúc cho thấy sự khác biệt rõ rệt trên cả ba khía cạnh: tần suất mua, khoảng cách giữa các lần mua và tỷ lệ mua lại.

Nhóm Loyal nổi bật với tần suất rất cao (56 đơn), khoảng cách ngắn (5 ngày) và reorder rate cao nhất (74.7%), cho thấy hành vi mua mang tính thói quen và mức độ trung thành cao.

Ngược lại, nhóm Churn Risk có tần suất thấp (6 đơn), khoảng cách dài (15 ngày) và reorder rate thấp (24.5%), phản ánh dấu hiệu suy giảm tương tác rõ rệt.

Các nhóm trung gian thể hiện quá trình chuyển đổi hành vi: Regular có mức tương tác ổn định (27 đơn, 9 ngày, 60.7%), trong khi Occasional bắt đầu giảm tần suất và tăng khoảng cách mua (12 đơn, 17 ngày, 45.8%). Đặc biệt, New Customers có tần suất rất thấp (3 đơn) nhưng khoảng cách mua ngắn (8 ngày), cho thấy còn ở giai đoạn đầu hình thành thói quen.

Tóm lại:

Mô hình phân khúc dựa trên RFM (Với Monetary là Reorder Rate thay cho Thành Tiền và dựa trên Rule Base) đã cho thấy bức tranh rõ ràng về hành vi khách hàng: phần lớn

người dùng vẫn ở mức tương tác thấp và chưa hình thành thói quen mua ổn định, trong khi nhóm khách hàng giá trị cao (Loyal) còn chiếm tỷ trọng nhỏ.

Hành vi mua sắm có xu hướng phân hóa theo một “chuỗi giá trị” rõ ràng từ New → Occasional → Regular → Loyal hoặc ngược lại là Churn Risk, phản ánh quá trình hình thành hoặc suy giảm mức độ gắn bó. Ba KPI (Frequency, Recency, Reorder Rate) đóng vai trò hiệu quả trong việc phân biệt các trạng thái này khi so sánh với mức trung bình của toàn hệ thống.

Từ góc độ kinh doanh, cơ hội lớn nhất nằm ở việc chuyển đổi các nhóm trung gian (Occasional, Regular) thành Loyal, đồng thời giảm tỷ lệ Churn Risk thông qua các chiến lược giữ chân và cá nhân hóa. Điều này sẽ giúp gia tăng giá trị vòng đời khách hàng và tối ưu hiệu suất toàn bộ hệ thống.

3.4. Đề xuất

Dựa trên các insight từ phân tích sản phẩm và hành vi khách hàng, một số định hướng tối ưu có thể được triển khai như sau:

Về **hiển thị sản phẩm (Product Visibility)**, cần ưu tiên các ngành hàng chủ lực như *Produce, Dairy Eggs, Snacks* trên homepage và kết quả tìm kiếm, do đây là nhóm đóng góp phần lớn đơn hàng. Đồng thời, các sản phẩm “core” như banana hay organic items nên được đặt ở vị trí nổi bật nhằm tăng khả năng chuyển đổi.

Đối với **hành vi mua theo cụm**, nên triển khai các chiến lược **cross-sell và bundle** dựa trên các cặp sản phẩm thường mua cùng (ví dụ: bananas – avocado). Việc gợi ý sản phẩm bổ trợ ngay trong quá trình thêm vào giỏ hàng sẽ giúp tăng giá trị đơn hàng.

Ngoài ra, các sản phẩm thường được thêm vào giỏ ở giai đoạn đầu nên được ưu tiên hiển thị như “**Recommended First Items**”, giúp định hướng hành vi mua và rút ngắn thời gian ra quyết định.

Về **marketing và giữ chân khách hàng**, cần tập trung vào nhóm **Churn Risk (~30%)** thông qua các chiến dịch win-back như ưu đãi cá nhân hóa hoặc credit khi quay lại. Đồng thời, nhóm **Regular và Occasional (~55%)** nên được thúc đẩy bằng các chương trình loyalty (tích điểm, freeship) để chuyển đổi lên Loyal.

Cuối cùng, nên tối ưu **thời điểm tiếp cận** bằng cách gửi thông báo vào các khung giờ cao điểm (10h–16h, đầu tuần và cuối tuần) và triển khai **nhắc mua tự động theo chu kỳ (khoảng ngày 6–7)** để tận dụng hành vi mua lặp lại.

4. Xây dựng mô hình

4.1. Phân cụm Kmean

4.1.1. Chuẩn bị

Trong bối cảnh tập dữ liệu giao dịch có quy mô lớn (khoảng 32 triệu dòng), việc áp dụng trực tiếp khai phá luật kết hợp trên toàn bộ dữ liệu gặp hai nhóm vấn đề chính:

- Chi phí tính toán
- Tính đại diện cho kết quả

Về mặt tài nguyên, các thuật toán như Apriori hoặc FP-Growth phải xử lý số lượng tổ hợp mặt hàng tăng rất nhanh theo số chiều dữ liệu. Khi số lượng giao dịch lớn, việc quét dữ liệu nhiều lần và lưu trữ các tập phổ biến trung gian làm tăng đáng kể yêu cầu về bộ nhớ và thời gian xử lý. Đặc biệt, khi giảm ngưỡng support để tìm các mẫu hiếm hơn, chi phí tính toán tăng mạnh, khiến quá trình thử nghiệm tham số trở nên tốn kém.

Bên cạnh đó, các luật kết hợp được từ toàn bộ dataset đều dựa trên các chỉ số tổng hợp như support và confidence tính trên tất cả khách hàng. Điều này dẫn đến việc các hành vi đặc thù theo từng nhóm bị “trung bình hóa”. Một luật có thể có support cao vì phổ biến ở một nhóm lớn, nhưng lại không xuất hiện ở các nhóm khác; ngược lại, những luật mang tính đặc trưng cho các nhóm nhỏ có thể không đạt ngưỡng và bị loại bỏ.

Do đó, cùng một luật kết hợp có thể mang ý nghĩa khác nhau giữa các nhóm khách hàng: quan trọng với nhóm này nhưng không liên quan với nhóm khác. Đây là cơ sở để đưa bước phân cụm (K-Means) vào trước, nhằm chia dữ liệu thành các nhóm có hành vi tương đồng, từ đó khai phá luật kết hợp trong từng cụm để giữ được tính đặc trưng và giảm chi phí xử lý.

Trong giai đoạn chuẩn bị đặc trưng cho bài toán phân cụm, các biến đầu vào không được sử dụng một cách rời rạc mà được tổ chức lại thành các nhóm mang ý nghĩa hành vi.

Cách tiếp cận này nhằm đảm bảo mỗi cụm khách hàng sau khi phân nhóm có thể được diễn giải theo các khía cạnh rõ ràng thay vì chỉ dựa trên các giá trị số thuần túy.

4.1.2. Thuộc tính sử dụng

Các thuộc tính được dùng để phân cụm gồm:

- **average_days_between_orders:** số ngày trung bình giữa hai lần mua → phản ánh khoảng cách thời gian giữa các giao dịch
- **total_orders:** tổng số đơn hàng của mỗi khách hàng → phản ánh mức độ hoạt động tích lũy
- **avg_basket_size:** số lượng sản phẩm trung bình trong mỗi đơn → phản ánh quy mô giỏ hàng theo từng lần mua
- **reorder_rate:** tỷ lệ sản phẩm được mua lại → phản ánh mức độ lặp lại hành vi mua
- **weekend_ratio:** tỷ lệ đơn hàng phát sinh vào cuối tuần → phản ánh phân bố giao dịch theo ngày trong tuần
- **night_order_ratio:** tỷ lệ đơn hàng vào ban đêm → phản ánh phân bố giao dịch theo khung giờ
- **organic_ratio_order:** tỷ lệ đơn hàng có chứa sản phẩm organic → phản ánh mức độ ưu tiên sản phẩm organic
- **unique_products:** số lượng sản phẩm khác nhau đã mua → phản ánh độ rộng danh mục sản phẩm (giá trị tuyệt đối, phụ thuộc quy mô user)

Dưới đây là công thức tính của từng chỉ số:

- $\text{total_orders} = \text{COUNT}(\text{order_id})$
- $\text{average_days_between_orders} = \text{AVG}(\text{days_since_prior_order})$ (loại bỏ đơn đầu tiên)
- $\text{reorder_rate} = \text{SUM}(\text{reordered}) / \text{COUNT}(\text{product_id})$
- $\text{avg_basket_size} = \text{total_items} / \text{total_orders}$

- $\text{unique_products} = \text{COUNT}(\text{DISTINCT product_id})$
- $\text{weekend_ratio} = \text{weekend_orders} / \text{total_orders}$ ($\text{order_dow} \in \{0, 6\}$)
- $\text{night_order_ratio} = \text{night_orders} / \text{total_orders}$ ($\text{order_hour_of_day} \in \{22-5\}$)
- $\text{organic_ratio_order} = \text{SUM}(\text{is_organic}) / \text{COUNT}(\text{product_id})$


Cụ thể, tập đặc trưng được chia thành 5 nhóm chính:

- Tần suất: gồm biến **average_days_between_orders**, phản ánh khoảng cách trung bình giữa hai lần mua. Giá trị nhỏ tương ứng với tần suất mua cao hơn.
- Giá trị: gồm **avg_basket_size** và **total_orders**, đại diện cho quy mô chi tiêu và mức độ hoạt động tích lũy của khách hàng.
- Đa dạng: gồm **reorder_rate** và **unique_products**, thể hiện mức độ lặp lại sản phẩm và độ rộng danh mục sản phẩm mà khách hàng đã mua.
- Hành vi mua theo thời gian: gồm **weekend_ratio** và **night_order_ratio**, phản ánh phân bố giao dịch theo thời điểm (cuối tuần và ban đêm).
- Organic: gồm **organic_ratio_order**, đo tỷ trọng đơn hàng có chứa sản phẩm organic.

Việc nhóm các biến theo cấu trúc trên dựa trên hai cơ sở:

- Mỗi nhóm đại diện cho một chiều hành vi riêng biệt (tần suất, giá trị, sở thích, thời điểm, loại sản phẩm), giúp giảm tình trạng các biến có ý nghĩa tương tự nhưng bị phân tán.
- Các cụm sau khi tạo ra có thể được mô tả theo từng nhóm đặc trưng (ví dụ: cụm có tần suất cao nhưng đa dạng thấp), thay vì phải diễn giải từng biến riêng lẻ.

Cách tổ chức này không làm thay đổi thuật toán K-Means (vẫn hoạt động trên toàn bộ vector đặc trưng), nhưng tạo nền tảng cho việc phân tích kết quả phân cụm ở các bước tiếp theo.



4.1.3. Chọn số cụm K

Việc lựa chọn số cụm k được quyết định dựa trên sự kết hợp giữa hai phương pháp định lượng: Elbow Method và Silhouette Analysis trên tập dữ liệu đã được chuẩn hóa bằng MinMaxScaler. Sau bước chuẩn hóa dữ liệu, mô hình K-Means được triển khai trong thư viện sklearn để thực hiện phân cụm khách hàng.

Phương pháp Khuỷu tay (Elbow Method)


Dựa trên chỉ số SSE (Sum of Squared Errors - Tổng bình phương sai số trong cụm):

- **Giai đoạn $k = 1 \rightarrow 3$:** Giá trị SSE giảm rất mạnh (từ khoảng 130,000 xuống còn xấp xỉ 75,000). Điều này cho thấy việc tăng số cụm giúp cô lập các điểm dữ liệu vào các phân vùng tập trung hơn một cách hiệu quả.
- **Giai đoạn $k > 3$:** Tốc độ giảm của SSE bắt đầu chậm lại rõ rệt
- **Kết luận:** Điểm "khuỷu tay" (Elbow point) xuất hiện tại $k = 3$. Tại đây, sự cân bằng giữa độ phức tạp của mô hình (số cụm) và độ chính xác (SSE) đạt mức tối ưu.


Phương pháp Silhouette

Để củng cố cho lựa chọn từ Elbow, biểu đồ Silhouette Score cung cấp cái nhìn về chất lượng phân tách giữa các cụm:

- **Đỉnh cao nhất:** Silhouette Score đạt giá trị cực đại (khoảng 0.30) tại $k = 3$.
- **Ý nghĩa:** Chỉ số này cao nhất tại $k=3$ chứng tỏ rằng ở cấu hình này, các đối tượng trong cùng một cụm có độ tương đồng cao và khoảng cách giữa các cụm là đủ xa để phân biệt rõ ràng.




Kết quả phân cụm được trực quan hóa trên không gian 2 chiều sau PCA cho thấy dữ liệu được chia thành 3 cụm tương ứng với $k = 3$. Cụm 0 tập trung ở vùng có PC2 thấp và phân bố hẹp, trong khi cụm 1 và cụm 2 trải rộng hơn trên không gian, đặc biệt cụm 2 chiếm phần lớn vùng PC1 dương. Ngoài ra, tồn tại vùng chồng lấn nhẹ giữa cụm 1 và cụm 2, cho thấy một phần khách hàng có đặc điểm trung gian. Tổng thể, các cụm được tách tương đối rõ ràng, phù hợp với lựa chọn số cụm ở bước trước.



Phân bố khách hàng theo cụm cho thấy dữ liệu không được chia đều giữa các nhóm, trong đó một cụm chiếm tỷ trọng vượt trội so với hai cụm còn lại, phản ánh sự tập trung hành vi ở một nhóm chính.

- Cụm 0: 113,906 user chiếm (55.2%)
- Cụm 2: 52,099 user chiếm (25.3%)
- Cụm 1: 40,204 user chiếm (19.5%)




Từ các biểu đồ trung bình theo cụm, có thể rút ra một số quan sát ban đầu:

- Cụm 2 có total_orders = 37.12, cao hơn ~5 lần cụm 0 (7.36) và ~3.4 lần cụm 1 (11.01), đồng thời average_days_between_orders = 9.41 thấp nhất → tần suất mua dày hơn
- Cụm 2 có unique_products = 126.00, cao hơn ~3.1 lần cụm 0 (40.37) → độ đa dạng sản phẩm cao hơn
- Cụm 2 có reorder_rate = 0.65, cao hơn cụm 0 (0.34) và cụm 1 (0.41) → mức độ lặp lại sản phẩm cao hơn

- Cụm 1 có `night_order_ratio` = 0.21, cao hơn cụm 0 (0.00) và cụm 2 (0.03) → tập trung giao dịch ban đêm
- `avg_basket_size` giữa các cụm không chênh lệch lớn (9.37–11.50), biên độ ~2.13 sản phẩm

Tuy nhiên, các biểu đồ này chỉ thể hiện từng biến riêng lẻ mà chưa đặt trong cấu trúc nhóm đặc trưng (tần suất, giá trị, đa dạng, thời gian, organic), nên chưa cho thấy bức tranh hành vi tổng thể của từng cụm. Đồng thời, do không có đường tham chiếu từ toàn bộ dataset, các giá trị trung bình hiện tại không cho biết mức chênh lệch là đáng kể hay chỉ là dao động nhỏ quanh mức chung; ngoài ra, việc chỉ sử dụng mean có thể che giấu phân phối lệch hoặc sự tồn tại của các nhóm con bên trong mỗi cụm.

a. Nhóm tần suất




Từ biểu đồ nhóm Tần suất, có thể so sánh trực tiếp từng cụm với mức trung bình toàn bộ dataset (15.47 ngày):

- Cụm 2: 9.41 ngày, thấp hơn tổng thể 6.06 ngày (~39%) → tần suất mua cao hơn

- Cụm 0: 17.89 ngày, cao hơn tổng thể 2.42 ngày (~16%) → tần suất mua thấp hơn
- Cụm 1: 16.45 ngày, cao hơn tổng thể 0.98 ngày (~6%) → gần mức trung bình

Nhìn tổng thể, cụm 2 có tần suất mua cao hơn rõ rệt so với mặt bằng chung, trong khi cụm 0 và cụm 1 nằm gần hoặc thấp hơn về tần suất, tạo thành hai nhóm có hành vi mua thưa hơn so với cụm 2.

b. Giá trị




Từ nhóm Giá trị, có thể so sánh từng cụm với mức trung bình toàn dataset ($\text{avg_basket_size} = 9.95$, $\text{total_orders} = 15.59$):

- Cụm 2: $\text{avg_basket_size} = 11.50$ (+1.55, ~16%), $\text{avg_total_orders} = 37.12$ (+21.53, ~138%)
- Cụm 1: $\text{avg_basket_size} = 9.60$ (-0.35, ~-3.5%), $\text{avg_total_orders} = 11.01$ (-4.58, ~-29%)
- Cụm 0: $\text{avg_basket_size} = 9.37$ (-0.58, ~-5.8%), $\text{avg_total_orders} = 7.36$ (-8.23, ~-53%)

Nhìn tổng thể, cụm 2 có giá trị giao dịch cao hơn rõ rệt so với mặt bằng chung ở cả quy mô giỏ hàng và tổng số đơn, trong khi cụm 0 và cụm 1 đều thấp hơn mức trung bình, với cụm 0 thấp hơn mạnh hơn về tổng số đơn.


c. Nhóm đa dạng



Từ nhóm đa dạng, so sánh với mức trung bình toàn dataset ($\text{reorder_rate} = 0.43$, $\text{unique_products} = 64.54$):

- Cụm 2: $\text{reorder_rate} = 0.65$ (+0.22, ~51%), $\text{unique_products} = 126.00$ (+61.46, ~95%)
- Cụm 1: $\text{reorder_rate} = 0.41$ (-0.02, ~-4.7%), $\text{unique_products} = 53.36$ (-11.18, ~-17%)
- Cụm 0: $\text{reorder_rate} = 0.34$ (-0.09, ~-21%), $\text{unique_products} = 40.37$ (-24.17, ~-37%)

Nhìn tổng thể, cụm 2 có cả unique_products và reorder_rate đều cao hơn đáng kể so với tổng thể, cho thấy vừa mở rộng danh mục sản phẩm vừa có xu hướng mua lặp lại, trong khi đó cụm 0 và cụm 1 đều thấp hơn mức trung bình ở cả hai chỉ số. Tuy nhiên, do reorder_rate phản ánh mức độ mua lặp lại sản phẩm, giá trị cao không thể tự diễn giải là tích cực hay tiêu cực nếu không đặt trong tương quan với unique_products : ví dụ cụm 2 có reorder_rate cao (+51%) nhưng đồng thời unique_products cũng cao (+95%), nên hành vi không phải là chỉ lặp lại mà vẫn có mở rộng danh mục. Trong các trường hợp khó phân biệt, cần phân tích đồng thời hai chỉ số thay vì đánh giá riêng lẻ.



Do `unique_products` là giá trị tuyệt đối nên chịu ảnh hưởng bởi quy mô cụm (cụm 2 có nhiều user hơn → tổng số sản phẩm khác nhau cao hơn), chỉ số này được thay thế bằng `product_diversity` để chuẩn hóa theo tỷ lệ.


- `product_diversity`: Phản ánh mức độ đa dạng trong hành vi mua sắm. Giá trị cao hay thử sản phẩm mới (explore); giá trị thấp = chỉ mua vài sản phẩm quen thuộc (focus).
- $\text{product_diversity} = \text{unique_products} / \text{total_items}$

Từ biểu đồ `product_diversity` (tổng thể = 0.57):

- Cụm 0: 0.66 (+0.09, ~16%)
- Cụm 1: 0.59 (+0.02, ~3.5%)
- Cụm 2: 0.35 (-0.22, ~-39%)

Nhìn tổng thể, sau khi chuẩn hóa, cụm 0 có mức độ đa dạng cao hơn rõ rệt so với tổng thể, cụm 1 gần mức trung bình, trong khi cụm 2 thấp hơn đáng kể, cho thấy hành vi tập trung vào một số sản phẩm lặp lại thay vì mở rộng danh mục.

d. Hành vi mua theo thời gian




Từ nhóm Hành vi mua theo thời gian, so sánh với mức trung bình toàn dataset ($\text{weekend_ratio} = 0.32$, $\text{night_order_ratio} = 0.05$):

- Cụm 1: $\text{weekend_ratio} = 0.34$ (+0.02, ~6%), $\text{night_order_ratio} = 0.21$ (+0.16, ~320%)
- Cụm 2: $\text{weekend_ratio} = 0.31$ (-0.01, ~-3%), $\text{night_order_ratio} = 0.03$ (-0.02, ~-40%)
- Cụm 0: $\text{weekend_ratio} = 0.32$ (~0), $\text{night_order_ratio} = 0.00$ (-0.05, -100%)

Nhìn tổng thể, sự khác biệt giữa các cụm chủ yếu đến từ night_order_ratio , khi cụm 1 cao hơn rõ rệt so với tổng thể (+320%), trong khi cụm 0 và cụm 2 thấp hơn; ngược lại, weekend_ratio gần như không có khác biệt đáng kể giữa các cụm.

e. Ưa thích sản phẩm Organic



Từ nhóm Organic, so sánh với mức trung bình toàn dataset ($\text{organic_ratio_order} = 0.27$):

- Cụm 2: 0.32 (+0.05, ~18.5%)
- Cụm 1: 0.27 (~0)
- Cụm 0: 0.25 (-0.02, ~-7.4%)

Nhìn tổng thể, cụm 2 có tỷ lệ mua sản phẩm organic cao hơn so với mặt bằng chung, trong khi cụm 1 gần mức trung bình và cụm 0 thấp hơn, cho thấy sự khác biệt về xu hướng lựa chọn sản phẩm theo tiêu chí organic giữa các cụm.

4.1.4. Kết luận

Kết quả phân cụm bằng K-Means ($k = 3$) cho thấy dữ liệu khách hàng được tách thành ba nhóm có sự khác biệt rõ ràng theo các chiều tần suất, giá trị, đa dạng, thời gian và sở thích sản phẩm. Việc chuẩn hóa bằng Min-Max giúp các đặc trưng có cùng thang đo, trong khi cách tổ chức biến theo nhóm (tần suất, giá trị, đa dạng, thời gian, organic) cho phép diễn giải hành vi một cách có cấu trúc. Khi so sánh từng cụm với mức trung bình toàn dataset, các khác biệt không chỉ thể hiện ở từng biến riêng lẻ mà còn ở sự kết hợp

giữa các chỉ số, từ đó hình thành các “chân dung hành vi” riêng biệt cho từng nhóm khách hàng.

Cụm	Câu chuyện (Narrative)	Insight chính
Cụm 0	Đây là nhóm khách hàng mua không thường xuyên, với khoảng cách giữa các lần mua dài hơn so với hai nhóm còn lại. Giá trị mang lại thấp nhất do số lượng đơn ít. Tuy nhiên, họ lại có xu hướng thử nhiều sản phẩm khác nhau hơn so với các nhóm khác, thay vì mua lặp lại. Hành vi mua không tập trung vào thời điểm cụ thể và cũng ít quan tâm đến sản phẩm organic.	Nhóm mua thưa, giá trị thấp, khám phá nhiều, ít gắn bó
Cụm 1	Nhóm này có hành vi ở mức trung bình trên hầu hết các khía cạnh: tần suất, giá trị và mức độ đa dạng đều nằm giữa cụm 0 và cụm 2. Điểm khác biệt chính là họ có xu hướng mua vào ban đêm nhiều hơn rõ rệt so với hai nhóm còn lại. Ngoài ra, mức độ quan tâm đến sản phẩm organic cũng không lệch nhiều so với tổng thể.	Nhóm trung bình, đặc trưng theo thời gian mua (ban đêm)
Cụm 2	Đây là nhóm khách hàng hoạt động mạnh nhất, với tần suất mua cao hơn rõ rệt và tổng số đơn lớn hơn nhiều so với hai nhóm còn lại. Tuy nhiên, thay vì thử nhiều sản phẩm, họ có xu hướng tập trung vào một số sản phẩm quen thuộc và mua lặp lại nhiều lần. Đồng thời, nhóm này cũng có tỷ lệ chọn sản phẩm organic cao hơn so với các nhóm khác.	Nhóm giá trị cao, mua thường xuyên, tập trung sản phẩm, có xu hướng organic

Việc phân cụm trong bài toán này không nhằm tối ưu hóa chỉ số mô hình, mà đóng vai trò như một bước tiền xử lý để tái cấu trúc dữ liệu theo hành vi khách hàng. Khi toàn bộ

dataset được chia thành các nhóm có đặc điểm tương đồng theo các chiều tần suất, giá trị, đa dạng, thời gian và sở thích sản phẩm, mỗi cụm trở thành một không gian dữ liệu có tính đồng nhất cao hơn so với toàn bộ tập dữ liệu ban đầu.

Ý nghĩa chính của bước phân cụm:

- Giảm hiện tượng “trung bình hóa” khi phân tích trên toàn dataset, giúp giữ lại các mẫu hành vi đặc thù của từng nhóm
- Tạo điều kiện để các luật kết hợp phản ánh đúng ngữ cảnh hành vi (ví dụ: luật phổ biến ở nhóm mua thường xuyên có thể không tồn tại ở nhóm mua thưa)
- Giảm kích thước bài toán khi khai phá luật kết hợp, từ đó giảm chi phí tính toán.

4.2. Luật kết hợp cho từng cụm khách hàng

4.2.1. Chuẩn bị

Sau khi hoàn thành bước phân cụm, dữ liệu khách hàng được chia thành các nhóm có hành vi tương đồng, từ đó cho phép triển khai khai phá luật kết hợp trên từng cụm thay vì toàn bộ dataset. Cách tiếp cận này nhằm giảm chi phí tính toán do mỗi cụm có quy mô nhỏ hơn, đồng thời đảm bảo các luật được phản ánh đúng hành vi đặc trưng của từng nhóm khách hàng, thay vì bị “trung bình hóa” như khi xử lý trên toàn bộ dữ liệu.

Cụ thể, với mỗi cụm, tập giao dịch được tách riêng và áp dụng các thuật toán khai phá luật kết hợp để tìm các cặp hoặc nhóm sản phẩm thường xuyên xuất hiện cùng nhau. Các chỉ số như support, confidence và lift được tính toán trong phạm vi từng cụm, giúp đánh giá mức độ liên kết giữa các sản phẩm trong ngữ cảnh hành vi cụ thể.

Dữ liệu đầu vào bao gồm:

- Orders.csv
- Products.csv
- Order_product_prior.csv
- Customer_segmentation.csv

Dữ liệu gốc:

Shape: 32,434,489 dòng $\times$ 2 cột

Số giỏ hàng (đơn hàng): 3,214,874

Số sản phẩm duy nhất: 49,677

Cluster 0:

Shape: 7,509,390 dòng $\times$ 2 cột

Số giỏ hàng (đơn hàng): 838,264

Số sản phẩm duy nhất: 48,271

Cluster 1:

Shape: 4,099,627 dòng $\times$ 2 cột

Số giỏ hàng (đơn hàng): 442,594

Số sản phẩm duy nhất: 45,006

Cluster 2:

Shape: 20,825,472 dòng $\times$ 2 cột

Số giỏ hàng (đơn hàng): 1,934,016

Số sản phẩm duy nhất: 48,741

Thay vì sử dụng Apriori – vốn yêu cầu nhiều lần quét dữ liệu và sinh candidate itemsets theo cấp số nhân – phương pháp được thay thế bằng thuật toán dựa trên **Logical Operation (AND)** nhằm tối ưu tốc độ xử lý trên tập dữ liệu lớn.

Xây dựng hàm để triển khai thuật toán $AND \Rightarrow$ **logical_and_apriori(basket_df, min_support_ratio = 0.0001, min_confidence = 0.3)** sau đó lần lượt chạy hàm trên các cluster khác nhau

4.2.2. Phân tích hành vi từng cụm khách hàng

Phân tích nhằm xác định hành vi mua sắm của từng cụm khách hàng thông qua các luật kết hợp (Association Rules), bao gồm các chỉ số Support, Confidence, Lift và Score

(được tính theo công thức $\text{Confidence} \times (\text{Lift} - 1)$ chỉ cao khi đồng thời có tỷ lệ đồng mua đủ lớn (Confidence) và mức vượt kỳ vọng độc lập rõ rệt (Lift).)


Từ các chỉ số này kết hợp với cấu trúc mạng lưới sản phẩm, có thể nhận diện:

- Các cặp hoặc nhóm sản phẩm thường được mua cùng nhau
- Mức độ liên kết giữa các sản phẩm (mạnh/yếu dựa trên Lift và Score)
- Tính ổn định của hành vi mua (dựa trên Confidence)
- Phạm vi lựa chọn sản phẩm (thông qua cấu trúc mạng: cụm, vòng, hay tuyến tính)

Qua đó, đặc điểm hành vi của từng cụm khách hàng được suy ra dựa trên mô hình liên kết thực tế trong dữ liệu, thay vì giả định theo danh mục sản phẩm.


Cluster-0

	Luật (vế trái ⇒ vế phải)	Support	Confidence	Lift	P(B) ước tính (vế phải)	Score
0	omy Org Wild Quebec Blueberry Cream Top Yog & Fruit ⇒ omy Pacific Coast Strawberry Tri Yog	0.000433	0.699	904.784	0.000773	632.127
1	omy Pacific Coast Strawberry Tri Yog ⇒ omy Org Wild Quebec Blueberry Cream Top Yog & Fruit	0.000433	0.560	904.784	0.000619	506.287
2	omy Org Wild Quebec Blueberry Cream Top Yog & Fruit ⇒ omy Madagascar Vanilla Trilayer Yogyurt	0.000317	0.513	690.724	0.000742	353.500
3	omy Madagascar Vanilla Trilayer Yogyurt ⇒ omy Pacific Coast Strawberry Tri Yog	0.000366	0.494	638.490	0.000773	314.645
4	omy Pacific Coast Strawberry Tri Yog ⇒ omy Madagascar Vanilla Trilayer Yogyurt	0.000366	0.474	638.490	0.000742	302.021
5	omy Madagascar Vanilla Trilayer Yogyurt ⇒ omy Org Wild Quebec Blueberry Cream Top Yog & Fruit	0.000317	0.428	690.724	0.000619	294.962
6	Almond Milk Blueberry Yogurt ⇒ Almond Milk Peach Yogurt	0.000452	0.500	531.219	0.000941	265.110
7	Almond Milk Blueberry Yogurt ⇒ Almond Milk Strawberry Yogurt	0.000472	0.522	505.695	0.001033	263.667
8	Almond Milk Peach Yogurt ⇒ Almond Milk Blueberry Yogurt	0.000452	0.480	531.219	0.000904	254.693
9	Almond Milk Strawberry Yogurt ⇒ Almond Milk Blueberry Yogurt	0.000472	0.457	505.695	0.000904	230.784
10	Yotoddler Org Pear Spinach Mango Yog ⇒ Org Whole Milk Strawberry Beet Berry Yog Pouch	0.000552	0.509	440.601	0.001155	223.665
11	Almond Milk Peach Yogurt ⇒ Almond Milk Strawberry Yogurt	0.000451	0.479	463.743	0.001033	221.695



Dựa trên bảng AR trên ta thấy những đặc trưng rõ nét về thói quen mua sắm của nhóm khách hàng này:

- Dòng omy Org Wild Quebec hiện có Score cao nhất (632.1) với Lift đạt mức rất cao (từ 440.6 đến 904.7), cho thấy xác suất các cặp sản phẩm xuất hiện cùng nhau khá cao so với việc chọn mua ngẫu nhiên.
- Xác suất xuất hiện riêng lẻ của các sản phẩm ở vế phải chỉ dao động từ 0.06% đến 0.11%, chứng tỏ đây là một phân khúc khách hàng ngách với gu tiêu dùng rất riêng biệt.
- Tỷ lệ mua kèm (Confidence) nằm trong khoảng từ 42.8% đến 69.9%, đặc biệt là các mã dòng omy với tỷ lệ lặp lại lên đến gần 70% giữa các sản phẩm chính.
- Các quy luật hai chiều xuất hiện phổ biến với độ hỗ trợ (Support) khoảng 0.0004 xuất hiện khá thấp trên tổng các đơn hàng lý giải cho điều này là do số lượng đơn hàng quá lớn làm cho chỉ số support giảm xuống.




Đồ thị mạng lưới cho thấy Cụm 0 bị chia tách thành các nhóm biệt lập với các trọng số kết nối cụ thể:

- Toàn bộ các liên kết mạnh nhất chỉ diễn ra trong nội bộ từng thương hiệu, với các liên kết trên đồ thị có độ tin cậy đạt từ 0.48 đến 0.56, khẳng định khách hàng ưu tiên trải nghiệm chuyên sâu một dòng sản phẩm duy nhất.
- Các vị Đào, Dâu và Việt quất (Almond) của dòng sữa chua hạnh nhân tạo thành một vòng lặp kín với xác suất mua kèm đồng đều quanh mức 50% (cụ thể từ 0.48 đến 0.52), minh chứng cho thói quen mua đủ bộ hoặc nhu cầu thay đổi hương vị liên tục. Và đối với nhóm sản phẩm cho trẻ em và thực phẩm chức năng chủ yếu hình thành các cặp liên kết đơn lẻ.

Tóm lại: Khách hàng Cụm 0 tiêu dùng theo hệ sinh thái hương vị của từng thương hiệu riêng biệt. Doanh số của cụm phụ thuộc hoàn toàn vào tính đầy đủ của các biến thể sản phẩm trên kệ. Chiến lược hiệu quả nhất là tập trung đảm bảo tồn kho và triển khai các gói Mix vị cho những nhóm có cấu trúc tam giác để khai thác tối đa hành vi mua theo bộ.

Cluster 1:


	Luật (vế trái → vế phải)	Support	Confidence	Lift	P(B) ước tính (vế phải)	Score
0	omy Org Wild Quebec Blueberry Cream Top Yog & Fruit ⇒ omy Pacific Coast Strawberry Tri Yog	0.000474	0.618	727.040	0.000850	448.436
1	omy Pacific Coast Strawberry Tri Yog ⇒ omy Org Wild Quebec Blueberry Cream Top Yog & Fruit	0.000474	0.559	727.040	0.000768	405.501
2	omy Gingered Pear Trilayer Yogurt ⇒ omy Pacific Coast Strawberry Tri Yog	0.000352	0.498	586.675	0.000850	291.902
3	omy Madagascar Vanilla Trilayer Yogyurt ⇒ omy Pacific Coast Strawberry Tri Yog	0.000404	0.485	571.011	0.000850	276.509
4	omy Pacific Coast Strawberry Tri Yog ⇒ omy Madagascar Vanilla Trilayer Yogyurt	0.000404	0.476	571.011	0.000834	271.362
5	Dairy Free Coconut Milk Raspberry Yog Alternative ⇒ Dairy Free Coconut Milk Blueberry Yog Alternative	0.000325	0.456	582.914	0.000782	265.176
6	Grk Whole Milk Blended Blueberry Yog ⇒ Org Grk Whole Milk Blended Strawberry Yog	0.000314	0.523	502.783	0.001039	262.210
7	omy Gingered Pear Trilayer Yogurt ⇒ omy Org Wild Quebec Blueberry Cream Top Yog & Fruit	0.000312	0.441	573.933	0.000768	252.603
8	omy Pacific Coast Strawberry Tri Yog ⇒ omy Gingered Pear Trilayer Yogurt	0.000352	0.415	586.675	0.000707	242.993
9	Dairy Free Coconut Milk Blueberry Yog Alternative ⇒ Dairy Free Coconut Milk Raspberry Yog Alternative	0.000325	0.416	582.914	0.000714	242.184
10	omy Org Wild Quebec Blueberry Cream Top Yog & Fruit ⇒ omy Gingered Pear Trilayer Yogurt	0.000312	0.406	573.933	0.000707	232.543
11	omy Org Wild Quebec Blueberry Cream Top Yog & Fruit ⇒ omy Madagascar Vanilla Trilayer Yogyurt	0.000332	0.432	518.582	0.000834	223.778



Dựa trên bảng AR trên ta thấy những đặc trưng rõ nét về thói quen mua sắm của nhóm khách hàng này:

- Dòng omy Org Wild Quebec vẫn giữ Score cao nhất (448.4) với Lift đạt 727.0, trong khi các cặp còn lại dao động Lift từ 502.8 đến 586.7, cho thấy xác suất các sản phẩm xuất hiện cùng nhau cao hơn đáng kể so với trường hợp độc lập.
- Tỷ lệ mua kèm (Confidence) nằm trong khoảng 40.6% đến 61.8% phản ánh hành vi mua mang tính lặp cổ định và có xu hướng phân tán giữa nhiều lựa chọn.

- Các quy luật hai chiều vẫn xuất hiện rõ (Quebec $\rightleftharpoons$ Strawberry, Strawberry $\rightleftharpoons$ Madagascar, Strawberry $\rightleftharpoons$ Gingered Pear) cho thấy mối quan hệ hỗ trợ vẫn tồn tại nhưng Support khoảng 0.0003 – 0.0004.




Đồ thị mạng lưới cho thấy Cụm 1:

- Nhóm omy vẫn là trung tâm tạo thành mạng liên kết với Confidence các cạnh chính từ ~0.41 đến ~0.62.
- Nhóm Almond Milk không còn tạo vòng kín độc lập mà kết nối sang omy (Confidence ~0.47 – 0.51), cho thấy sự giao thoa giữa các dòng sản phẩm.
- Nhóm sản phẩm cho trẻ em (Yotoddler) có xu hướng liên kết với các nhóm Omy với Confidence ~0.50 và Support ~0.0005, phản ánh thêm được sở thích mua sản phẩm sữa chua đi kèm với các mặt hàng cho trẻ em

Tóm lại: Khách hàng Cụm 1 tiêu dùng theo cấu trúc đa cụm có liên kết chéo giữa các dòng sản phẩm, trong đó omy vẫn là trung tâm (Score 448). Doanh số của cụm phụ thuộc vào độ phủ danh mục và khả năng kết nối giữa các nhóm sản phẩm. Chiến lược phù hợp là đảm bảo tồn kho đa dòng (omy, Almond, Dairy Free, Greek) và khai thác cross-sell giữa các cụm đã có liên kết để tận dụng xu hướng mở rộng giỏ hàng.


Cluster 2:

	Luật (vế trái ⇒ vế phải)	Support	Confidence	Lift	P(B) ước tính (vế phải)	Score
0	omy Org Wild Quebec Blueberry Cream Top Yog & Fruit ⇒ omy Pacific Coast Strawberry Tri Yog	0.000480	0.657	693.699	0.000948	455.426
1	omy Pacific Coast Strawberry Tri Yog ⇒ omy Org Wild Quebec Blueberry Cream Top Yog & Fruit	0.000480	0.507	693.699	0.000731	351.073
2	Unsweetened Whole Milk Peach Grk Yog ⇒ Unsweetened Whole Milk Strawberry Yogurt	0.000372	0.507	672.611	0.000754	340.782
3	Unsweetened Whole Milk Mixed Berry Grk Yog ⇒ Unsweetened Whole Milk Peach Grk Yog	0.000310	0.495	675.120	0.000733	333.447
4	Unsweetened Whole Milk Strawberry Yogurt ⇒ Unsweetened Whole Milk Peach Grk Yog	0.000372	0.493	672.611	0.000733	330.972
5	Unsweetened Whole Milk Peach Grk Yog ⇒ Unsweetened Whole Milk Mixed Berry Grk Yog	0.000310	0.423	675.120	0.000627	285.442
6	Amaranth & Greek Yogurt Tots Snack Mighty 4 Kale Strawberry ⇒ Blueberry Mighty 4 Sweet Potato Millet & Greek Yogurt Tots Snack	0.000482	0.524	502.875	0.001043	263.209
7	Cream Top Blueberry Yogurt ⇒ Cream Top Strawberry on the Bottom Yog	0.000320	0.554	447.099	0.001238	246.990
8	Blueberry Mighty 4 Sweet Potato Millet & Greek Yogurt Tots Snack ⇒ Amaranth & Greek Yogurt Tots Snack Mighty 4 Kale Strawberry	0.000482	0.463	502.875	0.000920	232.151
9	omy Madagascar Vanilla Trilayer Yogyurt ⇒ omy Pacific Coast Strawberry Tri Yog	0.000383	0.469	494.792	0.000948	231.563
10	Mighty 4 Purple Carrot Blackberry Quinoa & Grk Yog Tots Snack ⇒ Blueberry Mighty 4 Sweet Potato Millet & Greek Yogurt Tots Snack	0.000395	0.490	470.185	0.001043	230.070
11	Butternut Squash & Carrots Snack Fiber & Protein Organic Pears Raspberries ⇒ Org Fiber & Protein Pear Blueberry & Spinach Baby Food	0.000438	0.499	440.316	0.001133	219.141



- Dòng omy vẫn có Score cao nhất (455.4, Lift 693.7, Confidence 0.657), các liên kết còn lại trải rộng với Lift 440 – 675 và Score 219 – 340.
- Xác suất xuất hiện vế phải 0.06% – 0.12% và Confidence chủ yếu 0.42 – 0.52 cho thấy hành vi mua ổn định mức trung bình
- Các cụm rõ ràng gồm: Greek Yogurt (Peach – Strawberry – Mixed Berry, Confidence ~0.49 – 0.51), nhóm snack (Mighty 4, Amaranth, Millet, Confidence ~0.49 – 0.52) và omy (liên kết cặp), với Support ~0.00031 – 0.00048.

Đồ thị mạng lưới xác nhận cấu trúc đa cụm độc lập: các nhóm sản phẩm tạo liên kết chặt trong nội bộ



Tóm lại: Khách hàng Cụm 2 mua theo từng nhóm sản phẩm riêng biệt (omy, Greek Yogurt, snack). Chiến lược phù hợp là tối ưu bundle trong từng danh mục thay vì cross-sell giữa các danh mục.

4.3. Hệ thống đề xuất dựa trên luật kết hợp

4.3.1. Chuẩn bị

Sau bước khai phá luật kết hợp trên từng cụm, các luật thu được được sử dụng để xây dựng một hệ thống gợi ý sản phẩm(Base Recommend đã được nhắc trong cơ sở lý thuyết), nhằm minh họa khả năng ứng dụng của mô hình trong thực tế. Hệ thống được triển khai dưới dạng một ứng dụng web sử dụng Streamlit, cho phép tương tác trực tiếp quan để hiểu hơn về thuật toán đề xuất.

Dữ liệu đầu vào bao gồm:

- Association_Rules_Cluster_0.csv
- Association_Rules_Cluster_1.csv
- Association_Rules_Cluster_2.csv

Kiến trúc hệ thống gồm các thành phần chính:

- `recommender.py` : chứa `class AssociationRecommender()` là thuật toán `base_recommend` mà nhóm đề xuất
- `app.py` : là phần giao diện sử dụng Streamlit

Luồng hoạt động:

- Người dùng thêm sản phẩm vào giỏ $\rightarrow$ hệ thống phải có thông tin về cụm mà khách hàng đang thuộc
- Truy xuất các luật tương ứng trong cụm đó
- Đề xuất theo công thức

$$\text{Score}(X \Rightarrow Y) = \text{Confidence}(X \Rightarrow Y) * (\text{Lift}(X \Rightarrow Y) - 1)$$


- Trả về các sản phẩm có khả năng được mua cùng

Streamlit đóng vai trò là một lớp giao diện nhẹ, cho phép xây dựng nhanh một ứng dụng tương tác nhằm phục vụ việc kiểm thử và trình diễn kết quả từ mô hình luật kết hợp. Thông qua đó, người dùng có thể nhập sản phẩm đầu vào, lựa chọn cụm khách hàng và quan sát trực tiếp các gợi ý sinh ra từ mô hình mà không cần triển khai backend phức tạp. Ngoài ra, Streamlit hỗ trợ hiển thị trực quan danh sách các luật kết hợp cùng các chỉ số đánh giá (ví dụ: support, confidence, lift), giúp việc kiểm tra tính hợp lý và so sánh giữa các luật dựa trên dữ kiện cụ thể trở nên minh bạch và nhanh chóng.


Cách khởi động: nhập vào terminal : “**streamlit run app.py**”

Như vậy, hệ thống này đóng vai trò như một lớp ứng dụng phía trên mô hình phân cụm và luật kết hợp, giúp chuyển các kết quả phân tích thành một công cụ có thể sử dụng trực tiếp để gợi ý sản phẩm theo từng nhóm hành vi khách hàng.

4.3.2. Kết quả



Đây là giao diện được thiết kế bên trái là giỏ hàng của người dùng bên phải là thanh Smart Recommendations. Khi người dùng add sản phẩm vào giỏ hàng hệ thống sẽ tính toán và đưa ra đề xuất



Sau khi thêm **Banana** vào giỏ hàng sản phẩm được đề xuất đầu tiên là **Oh My Yog! Pacific Coast Strawberry Trilayer Yogurt**. Phù hợp với luật:

Banana $\square$ *Oh My Yog! Pacific Coast Strawberry Trilayer Yogurt*

IV. KẾT LUẬN

Dựa trên toàn bộ quy trình phân tích dữ liệu giao dịch của nền tảng Instacart, dự án đã xây dựng được một khung tiếp cận xuyên suốt từ bài toán kinh doanh đến mô hình triển khai, bao gồm các bước: tiền xử lý dữ liệu, phân tích khám phá (EDA), xây dựng

dashboard, phân khúc khách hàng bằng K-Means và khai phá luật kết hợp để phục vụ hệ thống đề xuất.

Trước hết, xét trên quy mô dữ liệu, hệ thống bao gồm khoảng 3.2 triệu đơn hàng, 32.4 triệu sản phẩm và hơn 206 nghìn khách hàng. Các chỉ số hành vi trung vị như basket size = 8 sản phẩm, order gap = 7 ngày và reorder rate = 43.2% cho thấy hành vi mua sắm mang tính lặp lại theo chu kỳ ngắn và có cấu trúc tương đối ổn định. Cụ thể, với khoảng cách trung vị giữa hai lần mua là 7 ngày, có thể xác định rằng phần lớn khách hàng hình thành chu kỳ tiêu dùng theo tuần. Đồng thời, tỷ lệ mua lại ở mức 43.2% phản ánh một phần đáng kể sản phẩm trong giỏ hàng được lặp lại, tạo tiền đề cho các bài toán dự đoán và gợi ý sản phẩm.

Ở cấp độ sản phẩm, dữ liệu cho thấy cấu trúc nhu cầu có tính tập trung cao. Bảy ngành hàng chính chiếm gần 80% tổng số đơn hàng, trong đó riêng ngành Produce chiếm khoảng 29%. Ngoài ra, các sản phẩm dẫn đầu như Banana (~472 nghìn đơn) và Bag of Organic Bananas xuất hiện với tần suất vượt trội so với phần còn lại. Khi kết hợp với tỷ trọng sản phẩm organic đạt khoảng 32%, có thể xác định rằng hành vi tiêu dùng chủ yếu xoay quanh thực phẩm tươi sống và có xu hướng liên quan đến nhóm sản phẩm “healthy”. Đồng thời, phân tích giỏ hàng cho thấy các sản phẩm không được mua độc lập mà thường xuất hiện theo cụm, đặc biệt trong các nhóm trái cây, rau củ và thực phẩm hữu cơ. Điều này tạo cơ sở trực tiếp cho việc áp dụng các kỹ thuật cross-sell và recommendation.

Ở cấp độ khách hàng, mô hình phân khúc dựa trên ba chỉ số Frequency, Recency và Reorder Rate cho thấy sự phân hóa rõ rệt. Nhóm Loyal chỉ chiếm 8.1% nhưng có tần suất mua cao (56 đơn), khoảng cách mua ngắn (5 ngày) và tỷ lệ mua lại 74.7%. Ngược lại, hai nhóm Occasional (41.8%) và Churn Risk (30.6%) chiếm tổng cộng hơn 70% nhưng có mức độ tương tác thấp hơn, thể hiện qua tần suất mua thấp và khoảng cách giữa các lần mua dài hơn. Từ các dữ kiện này có thể xác định rằng giá trị hệ thống tập trung vào một nhóm nhỏ khách hàng, trong khi phần lớn người dùng chưa hình thành thói quen mua ổn định.

Kết quả phân cụm K-Means ($k = 3$) củng cố thêm nhận định này khi cho thấy sự khác biệt định lượng rõ ràng giữa các nhóm hành vi. Cụm 2 có total_orders = 37.12 (cao hơn

~138% so với trung bình), $reorder_rate = 0.65$ (cao hơn ~51%) và $average_days_between_orders = 9.41$ (thấp hơn ~39%), phản ánh nhóm khách hàng có tần suất cao và mức độ lặp lại lớn. Ngược lại, cụm 0 có $total_orders = 7.36$ và $average_days_between_orders = 17.89$, cho thấy hành vi mua thưa và giá trị thấp hơn. Cụm 1 nằm gần mức trung bình nhưng có $night_order_ratio = 0.21$, cao hơn đáng kể so với tổng thể (~0.05), thể hiện sự khác biệt theo thời gian mua. Việc phân cụm giúp tránh hiện tượng “trung bình hóa” khi phân tích toàn bộ dataset, từ đó giữ lại các đặc trưng hành vi riêng của từng nhóm.

Trên nền tảng đó, việc áp dụng luật kết hợp cho từng cụm khách hàng cho phép khai thác các mối quan hệ sản phẩm mang tính đặc thù thay vì tổng quát. Các luật được đánh giá thông qua ba chỉ số Support, Confidence và Lift, trong đó Lift đóng vai trò quan trọng trong việc xác định mức độ liên kết vượt quá trường hợp độc lập. Hệ thống đề xuất được xây dựng dựa trên công thức $Score = Confidence \times (Lift - 1)$, cho phép xếp hạng các sản phẩm gợi ý theo mức độ liên quan thực tế trong hành vi mua sắm. Cách tiếp cận này đảm bảo rằng các đề xuất không chỉ phổ biến mà còn có ý nghĩa về mặt hành vi.

Tổng thể, dự án cho thấy rằng việc kết hợp giữa phân tích hành vi khách hàng và khai phá luật kết hợp có thể chuyển đổi dữ liệu giao dịch thành các quyết định kinh doanh cụ thể. Cụ thể, các dữ kiện về chu kỳ mua (7 ngày), tỷ lệ mua lại (43.2%), sự tập trung ngành hàng (~80%) và phân hóa khách hàng (Loyal 8.1% so với >70% nhóm tương tác thấp) cung cấp cơ sở định lượng để thiết kế các chiến lược như cá nhân hóa đề xuất, tối ưu cross-sell và cải thiện giá trị mỗi đơn hàng. Như vậy, bài toán “tăng số lượng sản phẩm trên mỗi đơn hàng” không chỉ được giải quyết ở mức mô hình mà còn được liên kết trực tiếp với hành vi thực tế của khách hàng, đảm bảo tính khả thi trong triển khai.

Đề xuất cải tiến: Hiện tại, phân cụm K-Means được thực hiện offline trên toàn bộ dataset, dẫn đến việc khách hàng mới hoặc khách hàng vừa phát sinh hành vi sẽ chưa có nhãn cụm ngay lập tức. Điều này tạo độ trễ giữa thời điểm phát sinh dữ liệu và thời điểm hệ thống đề xuất có thể cá nhân hóa.

Do đó, cần bổ sung một mô hình phân loại (classification model) để dự đoán cụm khách hàng theo thời gian gần thực (near real-time), dựa trên các đặc trưng hành vi đã xây dựng.

V. DANH MỤC TÀI LIỆU THAM KHẢO

Customer Segmentation: RFM vs PCA vs Rule-Based (2025) – WP Force SSL
<https://wpforcssl.com/customer-segmentation-rfm-vs-pca-vs-rule-based-2025/>

Agrawal, R., Imieliński, T., & Swami, A. (1993). Mining association rules between sets of items in large databases. *Proceedings of the 1993 ACM SIGMOD International Conference on Management of Data*, 207–216. <https://doi.org/10.1145/170035.170072>

Few, S. (2006). *Information Dashboard Design: The Effective Visual Communication of Data*. O'Reilly Media.

Koch, R. (1998). *The 80/20 Principle: The Secret to Achieving More with Less*. Currency.

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, 29–39.

Big Data Analytics in Association Rule Mining: A Systematic Literature Review | Proceedings of the 2021 3rd International Conference on Big Data Engineering and Technology, <https://dl.acm.org/doi/abs/10.1145/3474944.3474951>

Optimization of Association Rule Mining on Large Datasets, Optimization of Association Rule Mining on Large Datasets,
<https://www.ijert.org/research/optimization-of-association-rule-mining-on-large-datasets-IJERTV3IS20807.pdf>

A Hybrid Approach for Customer Segmentation and Association Rule Mining in E-commerce, Integration of association rule mining and RFM analysis with machine learning for e-commerce customer value segmentation: a sustainable retail perspective: Abstract, Citation (BibTeX) & Reference | Bohrium
<https://www.bohrium.com/en/paper-details/integration-of-association-rule-mining-and-rfm-analysis-with-machine-learning-for-e-commerce-customer-value-segmentation-a-sustainable-retail-perspective/1144562939353628675-14939>

